

Empirische Häufigkeitsverteilungen

Zufallsvariablen sind Bestandteil der mathematischen Formalisierung eines zufälligen Prozesses.
Jetzt: Betrachte *empirische* Entsprechungen dieser ZV

Theorie	Empirie
Zufallsvariable X	Merkmal X
Träger T_X	Beobachtete Merkmalsausprägungen $\{a_1, \dots, a_k\}$ von X
Wktsfunktion $f_X(x)$	relative Häufigkeiten $f_X(a_j)$
Verteilungsfunktion $F_X(x)$	kumul. relative Häufigkeiten / empirische Verteilungsfunktion $F_n(x)$

Häufigkeitsverteilung: Notation & Terminologie

- ▶ $X, Y, \dots$ Bezeichnung für **Merkmale**
- ▶ n ist Anzahl der **Untersuchungseinheiten** $x(i)$, um zu kennzeichnen, wenn (Stichproben-)Werte geordnet sind
- ▶ $x_i, i \in \{1, \dots, n\}$ ist **beobachteter Wert** von Merkmal X für i -te Untersuchungseinheit
- ▶ $a_1, a_2, \dots, a_k$ mit $k \leq n$ sind (evtl. der Größe nach geordnete) verschiedene Werte der beobachteten Merkmalsausprägungen von X , wobei Anordnung " $<$ " ohne Bedeutung bei Nominalskalierung
- ▶ k = Anzahl der Kategorien bei kategorialen Merkmalen (bei stetigen Merkmalen ist k oft nicht oder nur marginal kleiner als n)

Klassenbildung, gruppierte Daten: Vor allem bei metrischen, stetigen (oder quasi-stetigen) Merkmalen oft Aggregation der Rohdaten durch Bildung geeigneter Klassen.
Dadurch kann sich das Skalenniveau ändern, was evtl. einen Informationsverlust bedeutet.

Eindimensionale Häufigkeitsverteilung

- Sortierung der Daten nach einem Merkmal
- Auszählen der Häufigkeiten der einzelnen Merkmalsausprägungen
- **Relative Häufigkeiten (Anteil)** = Häufigkeit einer Merkmalsausprägung / Anzahl UE
- **Kumulative relative Häufigkeiten** bei ordinal oder metrisch skalierten Merkmalen sinnvoll

Empirische Verteilungsfunktion $F_n(x) :=$ "(Anteil x_i mit Merkmalsausprägung $\leq x$)"

Absolute Häufigkeit der Ausprägung (a_j): $h(a_j) = h_j$ (Anzahl der x_i mit Wert a_j)

Relative Häufigkeit: $f(a_j) = f_j = h_j/n$

Absolute und relative Häufigkeitsverteilung: Spektrum von h_j, f_j mit j von 1 bis k

Häufigkeitsdaten: Statt der Rohdaten $x_1, x_2, \dots, x_n$ liegen bereits (geordnete) $a_j, \dots, a_k$ und deren Häufigkeiten h_j, f_j vor.

Häufigkeitsfunktion: $H(x) :=$ "(Anzahl der Werte $\leq x$)"

=> **Empirische Verteilungsfunktion** $F_n(x) = H(x)/n$

bzw. ****ECDF**** $F_n(x) = f(a_1) + f(a_2) + \dots + f(a_j) = \sum_{i: a_i \leq x} f_i$ (empirical cumulative distribution function)

Eigenschaften der ECDF:

- monoton wachsende Treppenfunktionen mit Sprüngen an den Ausprägungen a_j
- Sprunghöhen: $f_1, \dots, f_k$
- rechtsseitig stetig
- $F_n(x) = 0$ für $x < a_1$, $F_n(x) = 1$ für $x \geq a_k$