

Histogramm

Grafiktyp für eindimensionale Häufigkeitsverteilungen von metrischen Merkmalen (mindestens intervallskaliert).

Flächentreue Darstellung der Verteilung/relativen Häufigkeiten eines Merkmals, das in Klassen unterteilt wurde.

Geometrie: Achsenparallele Rechtecke

Ein **Histogramm** gibt einen grafischen Überblick darüber, wie „dicht“ verschiedene Intervalle des Wertebereichs mit Beobachtungen besetzt sind. Es ist also die empirische Version der Dichteverteilung. Zur Erstellung eines Histogramms teilen wir den Wertebereich der Beobachtungen auf, bilden also *Klassen* (Intervalle), mit denen die Daten quasi normiert werden.

Dafür brauchen wir die Anzahl der Beobachtungen, also die absoluten Häufigkeiten in den entsprechenden Klassen (n_k). Grafisch trägt man dann über den Intervallen (Abstand b_k) Balken auf, deren Höhe y_k proportional zur Anzahl der Beobachtungen pro Längeneinheit ist (Faktor n_k/n). Rechteckige Fläche f_k darüber repräsentiert die relative Häufigkeit der Klasse.

Es ist empfehlenswert, eine konstante Klassenbreite b_k zu wählen, so dass man direkt die Anzahlen aufrufen kann. Andernfalls muss man jeweils umrechnen. Zudem ist Interpretation der Balkenhöhe bei unterschiedlichen Klassenbreiten nicht angemessen im Sinne der Flächentreue!

Wie viele Klassen man wählt, ist subjektiv. Je nach Wahl der Intervalle können Strukturen verschwinden oder hinzukommen. Wenn man die Klassenbreite sehr groß setzt, kann es sein, dass mehrere Gipfel „verschmolzen“ werden zu einem einzelnen Gipfel.

Es ist generell ein massiver Nachteil von Histogrammen, dass der visuelle Eindruck so stark von der Wahl der Klassenbreite abhängt.

=> verschiedene Varianten ansehen und falls möglich Klassenbreite inhaltlich begründen!

Vorgehensweise bei Erstellung von Histogramm:

1. Aufteilung in Klassen (falls die Daten noch nicht gruppiert sind)
2. Bestimmung der Klassenhäufigkeiten n_k und der relativen Häufigkeiten $f_k = n_k/n$
3. Bestimmung der Histogramm-Höhen y_k mit $b_k \cdot y_k = f_k$ (also $y_k = f_k/b_k$), wobei b_k die Klassen-Breite (k) bezeichnet.

Vorsicht bei Rändern (siehe „*Kerndichteschätzer*“). Diese können lediglich Minimum und Maximum der Beobachtungen sein, aber auch darüber hinaus gehen.

Flächentreue Darstellung ist ähnlich zu Idee von *Dichtefunktionen*: Histogramm entspricht (stückweise konstanter) grober Approximation der Dichte, die tendenziell umso besser wird je kleinteiliger, also je geringer die gewählte Klassenbreite (Merke: Integral über Intervall der Dichtefkt. ist Wahrscheinlichkeit, Analogie im Histogramm ist Fläche über Intervall als tatsächliche relative Häufigkeit).

Vom Histogramm zur Kerndichte

Relative Häufigkeit in Histogramm-Klasse = Fläche der Histogramm-Säule (Fläche „unter der Kurve“)

Probleme :

- Ungesunde Abhängigkeit von Wahl der Klassengrenzen!
- Histogramm ist stückweise konstante Funktion, womit sich schwer rechnen lässt (analog zur Treppenfunktion bei empirischer Häufigkeitsverteilung).
- In größeren Datensätzen erkennt man im Histogramm kaum noch den stückweisen Charakter der Verteilung eines stetigen Merkmals. Man wünscht sich daher geradezu, es durch eine glatte stetige Funktion zu approximieren.

Deshalb: Ersetze Histogramm durch glatte stetige Funktion f (**Kerndichte**)


Diese stetige Kurve glättet zwar einige Details des Histogramms heraus, dafür gibt sie jedoch eine schöne optisch kompakte Visualisierung der Form der Verteilung und lässt sich oft durch eine einzige Formel als Funktion $f(x)$ beschreiben.

Die neue Dichte muss weiterhin Eigenschaften von Verteilungsfunktion erfüllen und wichtige Informationen des Histogramms erhalten. Also insbesondere, dass die überdeckte Gesamtfläche (Integral) = 1 ergibt und die Verteilung monoton wachsend (Treppenfunktion des Histogramms nicht negativ) ist.

Die Fläche unter der Dichte über beliebige Intervalle soll approximativ den relativen Häufigkeiten in diesen Intervallen entsprechen:

$$\int_a^b f(x) dx \approx 1/n * |\{x_i : a < x_i \leq b\}| \quad |\{\dots\}|: \text{Mächtigkeit der Menge, ergo Anzahl ihrer Elemente/Beobachtungen}$$

Beispiel: Histogramm und Dichte im Vergleich



Berechnung von 1D-Dichtekurven um Beobachtung in einem Mini-Intervall mit Breite $2h$:

$$f(x) = (1/n * |\{x_i : x_i \in [x_i - h, x_i + h]\}|) / 2h \quad h = \text{gewählte Bandbreite}$$

$(1/n * \text{Anzahl der Daten im Mini-Intervall um einzelne Beobachtung } x_i \text{ gewichtet durch Breite. Dann ist } f(x_i) \text{ gleich der Höhe des Rechtecks mit der Breite } 2h \text{ und repräsentiert relative Häufigkeit genau wie im Histogramm})$

Lässt man nun x und das Intervall $[x - h, x + h]$ über die x -Achse gleiten, erhält man den Graphen des gleitenden Histogramms. Vorher musste man noch mit Mengen hantieren und umständlich zählen, wie viele Datenpunkte in dem jeweiligen Mini-Intervall um Beobachtungen liegen. Stattdessen legt man nun einfach bequem eine Funktion über die gesamte x -Achse drüber.

Das gleitende Histogramm lässt sich mithilfe eines **Rechteckfensters**, das mit x über die Zahlenachse gleitet, anders schreiben. Sei dazu $k(u) = 1/2$ für $-1 \leq u < 1$, sonst 0 ein „Einheitsrechteckfenster“ oder „Kern“ mit der Fläche 1, der Breite 2 und der Höhe $1/2$ über dem Intervall $[-1 \leq u < 1]$:

Dann ist $1/h * k((x - x_i)/h) = 1/2h$ für $x_i - h \leq x < x_i + h$, sonst 0 ein über x_i zentriertes Rechteckfenster mit Fläche 1 und Breite $2h$.

$$\Rightarrow \text{Gleitendes Histogramm: } f(x) = 1/n \sum_{a}^b 1/h * k((x - x_i)/h) \quad (\approx \text{Integral von a bis b})$$

Durch die Summation werden zu jedem einzelnen x -Wert genau so viele Rechteckshöhen über x aufaddiert, wie x_i -Werte im Intervall $[x - h, x + h]$ liegen und anschließend durch n dividiert.

Gleitende Histogramme verfeinern zwar die grafische Darstellung, sie sind jedoch immer noch unstetige Treppenfunktionen (Aufsummierung von unstetigen Rechteckfenstern). Stetige Schätzer für Dichtekurven erhält man nun, indem man statt des Rechteckkerns **stetige Kerne** zulässt. In der Praxis werden folgende Kerne häufig verwendet: **Dreiecks-Kern**, **Epanechnikov-** und **Gaußkern**

Kerndichteschätzer (KDS)

$k(u)$ sei **Kernfunktion**, d.h. $k(u) \geq 0 \forall u$ und $\int_{-\infty}^{\infty} k(u) du = 1$

Dann ist der **Kerndichteschätzer** (auch: KDE - *kernel density estimator*)


$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n k\left(\frac{x - x_i}{h}\right)$$

Der Wert des KDS $\hat{f}(x)$ für den Wert x ist so etwas wie der Mittelwert der Auswertungen der Kernfunktionen $K((x - x_i)/h)$ über alle x_i .

Beispiele für Kernfunktionen:

Gauß-Kern	$k(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u^2\right)$
Epanechnikov-Kern	$k(u) = \max\left(0, \frac{3}{4}(1 - u^2)\right)$
Dreieck-Kern	$k(u) = \max(0, 1 - u)$



Speziell beim Gauss-Kern gehen immer alle Beobachtungen in die Schätzung der Kerndichte an einem beliebigen Punkt ein (nicht def. = 0 außerhalb Bandbreiten-Intervalls), aber Gausskern wird schnell sehr klein!



Abhängigkeit von der Wahl des Kerns ist eher unbedeutend. Für größeren Datenumfang n sind die Dichteschätzer mit Dreiecks-, Epanechnikov- und Gaußkern praktisch identisch.

Kerndichteschätzungen sind insbesondere bei größeren Datenmengen und (quasi-)stetigen Merkmalen Histogrammen vorzuziehen. Histogramme berücksichtigen nicht, ob Beobachtungen zentral oder am Rand der Klasse liegen, zählen nur die *Anzahl der Beobachtungen* innerhalb der Klassengrenzen.


#Kerndichteschätzungen (auch grober Rechteckskern) berücksichtigen die *Entfernung der benachbarten Punkte zum Auswertungspunkt*, mit abnehmender Gewichtung über die Distanz. Näher bei x liegende Datenpunkte werden stärker gewichtet als weiter von x entfernte. Dies entspricht der intuitiven Vorstellung, dass zu x benachbarte Werte größeren Einfluss auf die Schätzung der Dichte $f(x)$ haben sollten als weiter entfernte. Starke Überlappungen führen zu hoher Dichte an diesen hoch konzentrierten Stellen.



Bandbreite des Kerndichteschätzers:

Die Form von $\hat{f}(x)$ wird entscheidend von der **Bandbreite h** beeinflusst, aber kaum von der Wahl des Kernes. Für großes h sind die Fenster weit, die Kurve wird sehr glatt, aber wichtige Details können verschluckt werden. Ist umgekehrt die Bandbreite zu klein, wird die Kurve rauer und es treten jedoch möglicherweise Details hervor, die nur mit der Zufälligkeit der Stichprobe etwas zu tun haben und den Graphen unschön machen.

=> es gibt algorithmische Verfahren zur Bestimmung von optimaler Bandbreite aus den Daten



Kerndichteschätzer mit "optimaler" Bandbreite h (blau), zu kleiner (orange) und zu großer (lila) Bandbreite h .

Anmerkungen:

Es handelt sich bei Dichtekurven um mathematische Approximation einer empirischen Verteilung, die wiederum meist als Stichprobe vorliegt und somit einen gewissen Zufallscharakter haben sollte (also Beschreibung als Zufallsvariable macht Sinn).

Welche Dichteverteilung passt am besten auf Daten? Entscheidend sind die "dichtesten" Stellen, wo sich die meisten Datenpunkte konzentrieren. Die gewählte Verteilung muss mindestens diese Plateaus gut abbilden, sonst kann es gar vernünftige Repräsentation sein.

Um eine empirische Verteilung möglichst gut durch eine Dichtekurve zu repräsentieren, gibt es viele verschiedene Möglichkeiten. So kann man versuchen, bestimmte **parametrische** Formen von Verteilungen, wozu auch die gaußsche Normalverteilung zählt, durch geeignete Wahl der Parameter so zu spezifizieren, dass sie den Daten möglichst gut angepasst werden. Deutlich flexiblere Möglichkeiten bieten komplexere **nonparametrische** Approximationen von Dichtekurven.