

Grundbegriffe & Theorie:

- **Merkmalsträger, statistisches Merkmal:**

Merkmalsträger
(statistisches Objekt,
statistische Einheit)

- Einzelobjekt einer statistischen Untersuchung (kleinste betrachtete Einheit)
- genau definierter Gegenstand, Vorgang, Person o.ä.
- Notation: $\omega_i, i = 1, \dots, n$

Statistisches Merkmal

- Eigenschaft eines Merkmalsträgers
- Notation:
 - * X : Merkmal
 - * $a_1, \dots, a_k$: mögliche Merkmalsausprägungen
 - * $x_1, \dots, x_n$: beobachtete Ausprägungen bei den n betrachteten Merkmalsträgern

- **Grundgesamtheit:**

- Zusammenfassung aller relevanten Merkmalsträger
- Notation: $\Omega = \{\omega_1, \dots, \omega_n\}$
- Bemerkung: Ω kann auch (abzählbar) unendlich sein.

- **Merkmalsraum (Zustandsraum):**

- Zusammenfassung aller möglichen Merkmalsausprägungen
- Notation: $\mathbb{S} = \{a_1, \dots, a_k\}$
- Bemerkung: $\mathbb{S}$ kann auch überabzählbar unendlich sein (z.B. $\mathbb{S} = \mathbb{R}$).

- **Kodierung des Zustandsraumes:**

- eindeutige Abbildung $C : \mathbb{S} \rightarrow \mathbb{R}$ (in der Regel $\mathbb{N}$)
- rechentechnisch effizienter

- Damit lässt sich ein Merkmal als eindeutige Abbildung $X : \Omega \rightarrow \mathbb{R}, \omega_i \mapsto x_i$. beschreiben.

- Bemerkungen:

- später: Formalisierung von X als Zufallsvariable
- meist Beschränkung auf Teilgesamtheit (Teilpopulation) $T \subsetneq \Omega$, spätere Formalisierung von T als Stichprobe

Lösung Aufgabe 4

Theorie: Wie lassen sich statistische Merkmale kategorisieren?

Unterscheidung nach ...		
... Quantifizierbarkeit der Ausprägungen	Qualitative Merkmale: - nur zuordenbar (einstufig) - Beispiele: Wohnort, Name	Quantitative Merkmale: - mess- oder zählbar - Beispiele: Alter, Körpergröße
... Anzahl der Ausprägungen*	Diskrete Merkmale: - höchstens abzählbar unendlich viele mögliche Ausprägungen - Beispiele: Gehaltsklassen, Kaufverhalten	Stetige Merkmale: - überabzählbar unendlich viele mögliche Ausprägungen - Beispiele: Geschwindigkeit, Gewicht
... Direktheit der Informationsgewinnung	Beobachtbare Merkmale: - können direkt erhoben werden - Beispiel: Abiturnote	Latente Merkmale: - Operationalisierung über Indikatoren/Items notwendig - Beispiele: Bildungsgrad, Kreativität, Nutzen
... Skalenniveau	siehe unten	

Tabelle 1: Klassifikationsmöglichkeiten für Merkmale

Bemerkung:

- Es gibt Zwischenformen, sogenannte *quasi-stetige Merkmale*. Diese eigentlich diskreten Merkmale haben so viele mögliche Ausprägungen, dass sie wie stetige Merkmale behandeln werden können (z.B. Alter, Einkommen).
- Stetige Merkmale können durch Kategorisierung der Merkmalsausprägungen (Klassenbildung) in diskrete Merkmale transformiert werden.

	Natürliche Reihenfolge	Interpretierbarkeit von Differenzen	Natürlicher Nullpunkt	Natürliche Einheit
Nominalskala	nein	nein	nein	nein
Ordinalskala	ja	nein	nein	nein
Intervallskala	ja	ja	nein	nein
Verhältnisskala	ja	ja	ja	nein
Absolutskala	ja	ja	ja	ja

Tabelle 2: Charakterisierung der Skalenniveaus

Theorie: Erhebungsarten:

Methode

- **Beobachtung:**
 - Datengewinnung durch Erfassen von Sachverhalten, die nicht gesteuert werden
 - Systematisierung durch Beobachtungsprotokoll (zum Festhalten des Beobachteten) als Erhebungsinstrumentarium
 - Verdeckte Beobachtung: Der Beobachter gibt sich nicht zu erkennen.
 - Teilnehmende Beobachtung: Der Beobachter nimmt aktiv am Geschehen teil.
- **Befragung:**
 - mündlich, schriftlich, telefonisch, Internet
 - mit bzw. ohne Interviewer
 - Grundlage: Fragebogen
- **Experiment:**
 - Erzeugung der Daten durch Simulation der interessierenden Situation
 - Eine interessierende Situation wird künstlich erzeugt, um eine direkte oder indirekte (über Befragung) Beobachtung zu ermöglichen.
 - Anwendung vor allem in Naturwissenschaften, aber auch Sozialwissenschaften, Psychologie, Wirtschaftswissenschaften (Entscheidungssituationen)

Datenform

- **Querschnittanalyse:** Querschnitt durch eine Population zu festem Zeitpunkt
- **Zeitreihe:** Beobachtung eines Objektes über einen längeren Zeitraum hinweg (mehrere Messzeitpunkte)
- **Panel bzw. Längsschnittanalyse:** Beobachtung einer (Teil-)Population (mehrere Objekte) über mehrere Messzeitpunkte

Umfang

- **Vollerhebung (Totalerhebung):**
 - Untersuchung aller statistischen Einheiten der Grundgesamtheit
 - Beispiel: Volkszählung
 - Vorteil: Man erhält vollständige Informationen über die Grundgesamtheit, mögliche Unsicherheiten aufgrund fehlender Informationen sind somit ausgeschlossen.
 - Nachteil: Antwortverweigerungen, Kosten, eventuell nicht durchführbar (z.B. bei zerstörender Materialprüfung oder bei hypothetischen Grundgesamtheiten)
- **Teilerhebung (Stichprobe):**
 - Die Untersuchung beschränkt sich auf eine Teilgesamtheit, die für die Grundgesamtheit repräsentativ sein soll.
 - Verschiedene Auswahlmöglichkeiten: Quotenauswahl (repräsentativer Querschnitt), Zufallsauswahl (rein oder geschichtet)
 - Vorteil: geringere Kosten, generell weniger Aufwand als Vollerhebung
 - Problem: Merkmalsausprägungen für Grundgesamtheit unbekannt, Stichprobenfehler durch Ungewissheit der Repräsentativität

Herkunft

- **Primärerhebung.** Die Erhebung wird speziell im Hinblick auf die aktuelle Fragestellung durchgeführt.
- **Sekundärerhebung.** Es wird auf Daten aus anderen Erhebungen zu ähnlichen Fragestellungen zurückgegriffen, z.B. auf bereits vorhandene Originaldaten aus dem statistischen Jahrbuch.
- **Tertiärerhebung:** Für die Untersuchung stehen nur bereits transformierte oder komprimierte Daten zur Verfügung, z.B. einzelne Lagemaße wie Mittelwerte.

Lösung:

- (a) Testen der Wirkung eines neuen Düngemittels an Ackerpflanzen: Experiment, Panel, Stichprobe
- (b) Einschätzung der eigenen Fahrtüchtigkeit durch Führerscheininhaber im Vergleich zu anderen Autofahrern: Befragung, Querschnittanalyse, Stichprobe
- (c) Schätzung der durchschnittlichen Lebensdauer von Leuchtstoffröhren: Beobachtung, Panel, Stichprobe

Theorie: Bei Teilerhebungen wird noch weiter unterschieden in:

- **Nicht zufällige Auswahlverfahren:**

- Willkürliche Auswahl
- Bewusste Auswahl
- Quotenauswahl

- **Zufällige Auswahlverfahren:**

- Einfache Zufallsstichprobe:
 - * Alle Auswahlmöglichkeiten haben die gleiche Wahrscheinlichkeit.
- Geschichtete Stichprobe:
 - * uneingeschränkte Zufallsauswahl aus den einzelnen Schichten
 - * Alle Schichten sind (mit im Vorhinein festgelegter Anzahl) in der Stichprobe vertreten.
 - * Effizienzgewinn, falls die relevanten Merkmale innerhalb der Schichten homogen (Elemente innerhalb einer Schicht „ähnlich“) und zwischen den Schichten heterogen (Elemente aus verschiedenen Schichten „unterschiedlich“) sind
- Klumpenstichprobe
 - * Ziehen ohne Zurücklegen von (ganzen) Gruppe
 - * reduzierter Erhebungsaufwand
 - * Effizienzgewinn, falls jeder einzelne Klumpen ein gutes Abbild der Grundgesamtheit ist (Klumpen sind in sich heterogen, untereinander jedoch homogen.)

Lösung:

- (a) Eine Möglichkeit ist die Ziehung einer einfachen Zufallsstichprobe von beispielsweise 300 Wohnungen. Da aber bekannt ist, dass die Mietpreise stark von der „Region“ abhängig sind, erscheint es sinnvoll, die Ziehung geschichtet nach den „Regionen“ durchzuführen. Wenn man nun aus allen drei „Regionen“ einzeln eine Stichprobe zieht, kann man nicht nur Aufschluss über die Mietpreise in den einzelnen Regionen gewinnen, sondern auch das Gesamtmittel des Quadratmetermietpreises effizienter schätzen, d.h. mit geringerer Varianz.
- (b) Bei der Ziehung einer Stichprobe ist es sehr aufwendig, einzelne Schüler direkt auszuwählen. Voraussetzung hierfür wäre, dass eine Liste von Schülern der 8. Klasse vorliegt, aus welcher dann zufällig Schüler gezogen und anschließend befragt werden könnten. Eine derartige Liste ist jedoch selten vorhanden oder wird aus Datenschutzgründen nicht zur Verfügung gestellt. Daher liegt es nahe, jeweils ganze Klassen zu befragen. Dazu ist nur eine Zufallsauswahl von Schulklassen zu treffen. Bei diesem Auswahlverfahren handelt es sich um eine Klumpenstichprobe.