

Diskrete Zusammenhangsmaße (Kontingenztafel, Chi-Quadrat)

Kontingenztafel für diskrete und gruppierte Merkmale

Wie können wir in beobachteten Daten Aussagen über die (Un-)Abhängigkeit von Merkmalen machen?

⇒ **mehrdimensionale** oder **multivariate** Daten

Stichprobe mit Untersuchungseinheiten $i = 1, \dots, n$

► **Beobachtungen** (x_i, y_i, z_i) der **Merkmale** (X, Y, Z) ,

► Daten sind Tupel von Merkmalsausprägungen: $(x_1, y_1, z_1), \dots, (x_i, y_i, z_i), \dots, (x_n, y_n, z_n)$

(Im weiteren meist nur zwei Merkmale X, Y)

Darstellung, Präsentation von diskreten Merkmalen X und Y mit den Ausprägungen $a_1, \dots, a_k$ für X und $b_1, \dots, b_m$ für Y

► Skalenniveau von X, Y hier beliebig; X, Y können auch gruppierte metrische Merkmale sein.

► benutzt wird hier allerdings nur das *Nominal*skalenniveau der Merkmale

Kontingenztafel

Eine $(k \times m)$ -Kontingenztafel der **absoluten Häufigkeiten** besitzt die Form

	b_1	b_2	$\dots$	b_m	
a_1	h_{11}	h_{12}	$\dots$	h_{1m}	h_{1*}
a_2	h_{21}	h_{22}	$\dots$	h_{2m}	h_{2*}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
a_k	h_{k1}	h_{k2}	$\dots$	h_{km}	h_{k*}
	h_{*1}	h_{*2}	$\dots$	h_{*m}	n

$h_{ij} = h(a_i, b_j)$: absolute Häufigkeit dieser einzelnen Merkmals-Kombination

h_{1*} bis h_{k*} : Randhäufigkeiten von X ,

h_{*1} bis h_{*m} : Randhäufigkeiten von Y

mit

$$h_{i*} = \sum_{j=1}^m h_{ij} \quad (\text{auch Randsumme der Spalte oder Spaltensumme genannt})$$

$$h_{*j} = \sum_{i=1}^k h_{ij} \quad (\text{Randsumme der Zeile, Zeilensumme})$$

Die einzelnen Randsummen addieren sich zusammengenommen jeweils zu n !

$n = (k \times m)$: Gesamtanzahl der Beobachtungen

Die $(k \times m)$ -Kontingenztafel der relativen Häufigkeiten besitzt die Form

	b_1	b_2	...	b_m	
a_1	f_{11}	f_{21}	...	f_{1m}	f_{1*}
a_2	f_{21}	f_{22}	...	f_{2m}	f_{2*}
...	...	...	...	...	...
a_k	f_{k1}	f_{k2}	...	f_{km}	f_{k*}
	f_{*1}	f_{*2}	...	f_{*m}	1

$f_{ij} = h_{ij}/n$: Relative Häufigkeit der einzelnen Kombination (a_i, b_j)

$$f_{i*} = \sum_{j=1}^m f_{ij} = h_{i*}/n \text{ (i von 1 bis k): Relative Randhäufigkeit zu X}$$

$$f_{*j} = \sum_{i=1}^k f_{ij} = h_{*j}/n \text{ (j von 1 bis m): Relative Randhäufigkeit zu Y}$$

Die einzelnen relativen Randhäufigkeiten addieren sich zusammengekommen jeweils zu **1**!

=> Wenn relative Häufigkeiten gegeben sind, errechnen sich die absoluten Häufigkeiten durch Multiplikation der relativen Häufigkeit der einzelnen Kombination bzw. relativen Häufigkeit der Spalten/-Zeilensumme mit dem Stichprobenumfang **n**!

Bedingte Häufigkeiten

Zusammenhang zwischen X und Y aus gemeinsamen Häufigkeiten h_{ij} bzw. f_{ij} schwer ersichtlich.

Deshalb: Blick auf **bedingte Häufigkeiten**

⇒ Verteilung eines Merkmals für festen Wert des anderen Merkmals

Die **bedingte Häufigkeitsverteilung von Y unter der Bedingung $X = a_i$** (kurz $Y|X = a_i$) ist bestimmt durch

$$f_{Y|X}(b_m|a_i) = h_{im} / h_{i*} = f_{im} / f_{i*} \text{ (Wert geteilt durch Randwert der Zeile)}$$

Die **bedingte Häufigkeitsverteilung von X unter der Bedingung $Y = b_j$** (kurz $X|Y = b_j$) ist bestimmt durch

$$f_{X|Y}(a_k|b_j) = h_{kj} / h_{*j} = f_{kj} / f_{*j} \text{ (Wert geteilt durch Randwert der Spalte)}$$

Merksatz:

Bedingte Häufigkeitsverteilungen werden durch Division der h_{ij} bzw. f_{ij} durch die entsprechende Zeilen- bzw. Spaltensumme gebildet.

Man kann auch umgekehrt aus bedingten Häufigkeiten und Randhäufigkeiten die gemeinsamen Häufigkeiten ausrechnen, also etwa $h(a_1) \cdot f(b_1|a_1) = h(a_1, b_1)$ und umgekehrt.

Allgemein: Empirisch univariate Kennzahlen (wie etwa auch MW) können sowohl aus den primären Mikrodaten als auch den zugehörigen relativen Häufigkeiten berechnet werden.

Analyse von Zusammenhängen in Kontingenztabellen (2×2 -Tafel, diskrete Merkmale)

	b_1	b_2	
a_1	h_{11}	h_{12}	h_{1*}
a_2	h_{21}	h_{22}	h_{2*}
	h_{*1}	h_{*2}	n

Chancenverhältnis (Odds Ratio)

Die (empirischen) **bedingten Odds** für festes $X = ai$ sind definiert als

$$q(b_1, b_2 | X = a_i) = h_{i1} / h_{i2} \quad \text{umgekehrt für festes } Y = bi: \quad h_{1j} / h_{2j}$$

Bei den bedingten Odds isoliert man durch die Bedingung eine Zeile oder Spalte und vergleicht die dortigen Werte paarweise (hier sind es eh nur zwei Ausprägungen). Man erhält also für jede Bedingung quasi eine eindimensionale Kontingenztafel mit Subpopulationen.

Ein sehr einfaches Zusammenhangsmaß stellen die empirischen **relativen Chancen (Odds Ratio)** dar, die gegeben sind durch

$$q(b_1, b_2 | X = a_1, X = a_2) = q(b_1, b_2 | X = a_1) / q(b_1, b_2 | X = a_2) = (h_{11} / h_{12}) / (h_{21} / h_{22}) = (h_{11} * h_{22}) / (h_{21} * h_{12})$$

Man kann Odds-Ratio je nach Kontext als Chancenfaktor oder als Risikofaktor interpretieren.

Odds-Ratio gibt an, um welchen Faktor sich die Odds in den beiden betrachteten Subpopulationen unterscheiden:

$q = 1$: Odds in beiden Subpopulationen identisch

$q > 1$: Odds in Subpopulation ($X = a_1$) größer als für ($X = a_2$)

$q < 1$: Odds in Subpopulation ($X = a_1$) kleiner als für ($X = a_2$)

Wegen obigem Rechenergebnis wird Odds-Ratio auch das **Kreuzproduktverhältnis** genannt.

Aufgrund dieser Eigenschaft ist Odds-Ratio *symmetrisch*:

$$q(b_1, b_2 | X = a_1, X = a_2) = q(a_1, a_2 | Y = b_1, Y = b_2)$$

Solange man sozusagen den Tabellenausschnitt beibehält, sich somit das Kreuzproduktverhältnis nicht ändert, ist es für das Odds-Ratio egal, was man isoliert und was man bedingt.

Anmerkungen:

- Welche Odds und Odds-Ratios betrachtet man bzw. welche sind sinnvoll? Das ist eine inhaltliche Frage, die stark vom Kontext abhängt. Wegen Kreuzprodukt-Eigenschaft erhält man aber häufig ähnliche Werte für verschiedene Odds-Ratios.
- In der Praxis werden oft logarithmierte Odds-Ratios verwendet.

Verallgemeinerung auf $(k \times m)$ -Ausprägungen

Die Berechnungen in der (2×2) -Tafel sind zwar nett, aber in der Realität arbeiten wir mit großen Datensätzen und zig Merkmalsausprägungen. Dann kann man generell nur bedingte Odds(-Ratios) ausrechnen, indem man eine Bedingung/Referenzkategorie auswählt und/oder Spalten bzw. Zeilen (also mehrere Merkmalsausprägungen) zu sinnvollen Überkategorien zusammenfasst, um eine verkleinerte Kontingenztafel zu haben.

Wenn wir dann noch sehr viele Variablen analysieren braucht es entsprechend bessere Maße, um Zusammenhänge zu beschreiben und Variablen auf Unabhängigkeit zu untersuchen.

Exkurs: Eine perfekte Unabhängigkeit (also identische bedingte Odds für alle Kategorien und überall identische Odds-Ratios) ist in der Realität sehr selten, aber in der (2×3) -Tafel sähe das beispielsweise so aus:

	b_1	b_2	b_3	
a_1	10	20	30	60
a_2	20	40	60	120
	30	60	90	180

$$\begin{aligned} f_Y(b_1|a_1) &= f_Y(b_1|a_2) = f_Y(b_1) = 1/6 \\ f_Y(b_2|a_1) &= f_Y(b_2|a_2) = f_Y(b_2) = 1/3 \\ f_Y(b_3|a_1) &= f_Y(b_3|a_2) = f_Y(b_3) = 1/2 \end{aligned}$$

Exakt gleiche Zusammenhänge von links nach rechts, oben nach unten und umgekehrt
Lokale Odds-Ratios sind alle = 1

Maximale Abhängigkeit in (2×2) -Tafel sähe als Kontrast zum Beispiel so aus:

	b_1	b_2
a_1	0	10
a_2	20	0

Kontingenz und χ^2 -Koeffizient

=> Definiere allgemein anwendbares Zusammenhangsmaß für diskrete Merkmale

Idee:

1. Was wären die gemeinsamen Häufigkeiten $h_{ij} \sim$ bzw. $f_{ij} \sim$ falls, bei vorgegebenen Randverteilungen, die Merkmale X und Y empirisch unabhängig wären?

2. Quantifiziere "Abstand" der beobachteten gemeinsamen Häufigkeiten h_{ij} bzw. f_{ij} von den unter Unabhängigkeit erwarteten gemeinsamen Häufigkeiten.

X und Y "empirisch unabhängig" $\Leftrightarrow$ Verteilung von Y nicht beeinflusst von X und umgekehrt $\Leftrightarrow$ Bedingte relative Häufigkeiten von Y sind in jeder Teilpopulation $X = ai$ identisch, d.h. unbeeinflusst von X :

$$f_{(Y|X)}(b_j|a_1) = f_{(Y|X)}(b_j|a_2) = \dots f_{(Y|X)}(b_j|a_k) \quad \forall j=1, 2, \dots, m = f_Y(b_j)$$

$$f_{ij} \sim = f_{i.} * f_{.j} \quad (\text{analog } h_{ij} \sim = h_{i.} * h_{.j}) \quad [\text{vgl. stochastische Unabhängigkeit } p(A \cap B) = p(A) * p(B)]$$

Empirische Unabhängigkeit

Wie sehen also die **unter empirischer Unabhängigkeit erwarteten** (absoluten und relativen) Häufigkeiten $\tilde{h}_{ij}$ und $\tilde{f}_{ij}$ aus?

$$\begin{aligned} f_{Y|X}(b_j|a_i) &= f_Y(b_j), \dots, f_{Y|X}(b_m|a_i) = f_Y(b_m), \quad i = 1, \dots, k \\ \Leftrightarrow \frac{\tilde{h}_{ij}}{h_{i.}} &= \frac{h_{.j}}{n}; \forall i = 1, \dots, k; j = 1, \dots, m \\ \Leftrightarrow \tilde{h}_{ij} &= \frac{h_{i.} \cdot h_{.j}}{n}; \forall i = 1, \dots, k; j = 1, \dots, m \\ \Leftrightarrow \tilde{f}_{ij} &= f_{i.} \cdot f_{.j}; \forall i = 1, \dots, k; j = 1, \dots, m \end{aligned}$$

Beachte: $h_{ij} \sim$ sind üblicherweise keine ganzen Zahlen. Es handelt sich eben nur um einen Erwartungswert!

Unabhängigkeitstabelle

Idee: Vergleiche für jede Zelle die unter Unabhängigkeit erwarteten Häufigkeiten mit den tatsächlich in den Daten beobachteten Häufigkeiten.

Der χ^2 -Koeffizient ist bestimmt durch:

$$\chi^2 := \sum_{i=1}^k \sum_{j=1}^m \frac{(h_{ij} - \tilde{h}_{ij})^2}{\tilde{h}_{ij}} = \sum_{i=1}^k \sum_{j=1}^m \frac{\left(h_{ij} - \frac{h_{i.} \cdot h_{.j}}{n}\right)^2}{\frac{h_{i.} \cdot h_{.j}}{n}} = n \sum_i \sum_j \frac{(f_{ij} - f_{i.} \cdot f_{.j})^2}{f_{i.} \cdot f_{.j}}$$

Bei der Berechnung von χ^2 -Koeffizient werden die einzelnen Abweichungen vom EW quadriert, zum Erwartungswert ins Verhältnis gesetzt und aufsummiert. Durch diese Art der Rechnung erhalten große Abweichungen eine starke Gewichtung.

Eine Aufsummierung ergibt einzig mit immer positiven Einzelbeiträgen Sinn. Der Betrag der Abweichung wäre theoretisch eine Alternative, aber nur die quadrierten Abweichungen liefern eine interpretierbare Verteilung (siehe χ^2 -Test)

Beitrag zum χ^2 -Koeffizient (von einzelnen Beobachtungen/Randhäufigkeiten oder höherdimensional von Zellen aus Teilausschnitt der Daten durch Bedingen auf 2D-Kontingenztafel)

Standardized Pearson Residual: $(h_{ij} - h_{ij\sim}) / \sqrt{h_{ij\sim}}$

$\chi^2 \in [0, n(\min(k, m) - 1)]$

$\chi^2 = 0 \Leftrightarrow X$ und Y **empirisch unabhängig**

χ^2 groß $\Leftrightarrow$ starker Zusammenhang

χ^2 klein $\Leftrightarrow$ schwacher Zusammenhang

Schwachpunkt:

Wertebereich von χ^2 hängt vom Stichprobenumfang n und von der Dimension der Tafel ab.

Numerischer Wert deshalb schwierig direkt interpretierbar.

—► **Normierung**

Kontingenz-Koeffizient K:

$K = \sqrt{X^2 / n + X^2}$ mit Wertebereich $K \in [0, \sqrt{((M-1)/M)}]$, wobei $M = \min(k, m)$

Korrigierter Kontingenzkoeffizient:

$K^* := K / \sqrt{((M-1)/M)}$ mit Wertebereich $[0, 1]$

Durch diese Normierung (kein n , k und m mehr direkt in Formel und Werte zwischen 0 und 1) wird der diesbezügliche Vergleich unterschiedliche Datensätze einigermaßen sinnvoll.

Aber Vorsicht: Man kann K^* nicht linear interpretieren, also 10 Prozent höherer Wert ist nicht gleichbedeutend mit 10 Prozent stärkerer Abhängigkeit!

Eigenschaften des (korrigierten) Kontingenz-Koeffizienten:

- ◆ Sämtliche Maße benutzen nur das Nominalskalenniveau der Merkmale X und Y
- ◆ Es wird nur die *Stärke* des Zusammenhangs gemessen, nicht die Richtung wie beim Odds-Ratio
- ◆ Vorsicht ist geboten bei einem Vergleich von Kontingenztafeln gleicher Zellenzahl mit stark unterschiedlichen Stichprobenumfängen, da χ^2 mit wachsendem Stichprobenumfang wächst. So führt etwa eine Verzehnfachung von h_{ij} und $h_{\sim ij}$ zu zehnfachem χ^2
- ◆ Es gibt keine klare Faustregel, ab wann χ^2 -Wert oder seine Normierungen einen schwachen, mittleren oder starken Zusammenhang andeuten (und viel statistisches Rauschen!)
- ◆ Bei kleinen Stichproben können Kontingenz-Maße täuschend hoch oder niedrig sein. Bei riesigen Datensätzen erwartet man, dass sich Zufallseffekte ausgleichen ("law of large numbers"). Insbesondere sollte tatsächliche logische Unabhängigkeit annähernd durch Odds-Ratios nahe 1 und sehr niedriges χ^2 signalisiert werden.
- ◆ Es gibt weitere ähnliche Maße für diskrete Zusammenhänge wie *Cramers-v*

Mehrdimensionale Kontingenztafeln

Beispiel: Überleben beim Titanic-Untergang

- Mehrere diskrete Merkmale: Geschlecht, Klasse, Kind/ Erwachsene, Überleben (Ja/Nein)
- Darstellung durch geeignete bedingte und marginale Verteilungen
- Berechnung von Odds-Ratio zweier Merkmale bedingt auf ein drittes Merkmal
- grafische Darstellung durch *Mosaik-Plot*

Durch Isolation zweier Merkmale (Bedingen auf diese Variablen) können wir wie oben eine 2D-Kontingenztafel analysieren, die wir bildlich gesprochen aus dem höherdimensionalen Array "herausschneiden".

```
str(Titanic)

## 'table' num [1:4, 1:2, 1:2, 1:2] 0 0 35 0 0 0 17 0 118 154 ...
## - attr(*, "dimnames")=List of 4
## ..$ Class : chr [1:4] "1st" "2nd" "3rd" "Crew"
## ..$ Sex : chr [1:2] "Male" "Female"
## ..$ Age : chr [1:2] "Child" "Adult"
## ..$ Survived: chr [1:2] "No" "Yes"
```

⇒ echt multivariate Kontingenztafeln sind hochdimensionale Arrays

```
apply(Titanic, MAR = c(4, 1), FUN = sum)
```

```
##      Class
## Survived 1st 2nd 3rd Crew
##      No  122 167 528 673
##      Yes 203 118 178 212
```

⇒ (Gemeinsame) Randhäufigkeiten durch Akkumulation über restliche Merkmale/Dimensionen

Randverteilung von "Klasse":

```
apply(Titanic, FUN = sum, MAR = 1)
```

```
## 1st 2nd 3rd Crew
## 325 285 706 885
```

Bedingte Verteilungen von "Überleben" gegeben "Klasse":

```
apply(Titanic, FUN = sum, MAR = c(1, 4))/apply(Titanic, FUN = sum, MAR = 1)
```

```
##      Survived
## Class    No Yes
## 1st    0.38 0.62
## 2nd    0.59 0.41
## 3rd    0.75 0.25
## Crew   0.76 0.24
```

```
apply(Titanic, FUN = sum, MAR = c(2, 4))
```

```
##      Survived
## Sex      No Yes
## Male   1364 367
## Female  126 344
```

Bedingte Verteilung:

```
apply(Titanic, FUN = sum, MAR = c(2, 4))/apply(Titanic, FUN = sum, MAR = c(2))
```

```
##      Survived
## Sex      No Yes
## Male    0.79 0.21
## Female  0.27 0.73
```


Überlebens-Chance Frauen: $\frac{344}{126} \approx 2.7 \approx 3 : 1$

Überlebens-Chance Männer: $\frac{367}{1364} \approx 0.27 \approx 1 : 3$

Chancenverhältnis: 10

Mosaik-Plot:

- *Flächentreue* Darstellung von gemeinsamen Häufigkeiten
- Aufteilung erfolgt schrittweise: Zuerst nach *Einflussgrößen*, dann nach *Zielgröße* aufteilen
- Gut geeignet für mehrkategoriale ordinale Daten
- Auch für höhere Dimensionen geeignet (... angeblich)
- für 2 Dimensionen: entspricht gestapeltem Balkendiagramm mit variabler Balkenbreite
- relative Häufigkeiten: Aufteilung anhand des Anteils an den Spaltensummen
- Perfekte Unabhängigkeit zwischen "Überleben(schance)" und "Klasse" wäre gegeben, wenn horizontale Trennlinie für alle Klassen exakt auf der selben Höhe läge.



Man kann in bedingter Verteilung etwa auch Beitrag einzelner Zellen zum χ^2 -Koeffizienten farbig darstellen.