

Statistische Grafiken repräsentieren die *Ausprägungen* gewisser *Merkmale* in einem Datensatz durch die ästhetischen Eigenschaften *geometrischer Objekte*.

Grammar of Graphics

(Fast) jede sinnvolle Grafik lässt sich als Kombination der folgenden Basis-Elemente beschreiben:

► **Daten:** enthalten die *Beobachtungen* der dargestellten *Merkmale*, oft auch daraus abgeleitete Kennzahlen wie Anteile, Mittelwerte etc. mit entsprechendem Informationsverlust

■ **Geometrische Elemente:** Punkte, Linien, Rechtecke ...

● **Visuelle Zuordnungen:** *Ausprägungen* der in der Grafik dargestellten *Merkmale* werden durch sichtbare Eigenschaften der geometrischen Elemente repräsentiert, z.B. Position (vertikal/horizontal), Farbe, Größe, Form etc.

Skalen: Ordnen für ein gegebenes *Merkmal/Statistik* und ihrer *ästhetischen Zuordnung* allen *Ausprägungen* bestimmte Werte zu (z.B. Achsenabschnitte für Position, Farbpaletten für Kategorien) und legen damit auch Legenden und Achsenbeschriftungen fest

=> *Daten* werden über *ästhetische Eigenschaften* von *geometrischen Elementen* dargestellt.

zusätzlich:

- **Koordinatensysteme:** kartesische/ Polarkoordinaten/ logarithmische / ...
Damit verknüpft: Auswahl der geplotteten Intervalle (0 dabei oder nicht, wie starker Zoom)
- **Datentransformation:** Oft werden nicht Rohdaten selbst, sondern daraus abgeleitet Größen (Mittelwerte, Anteile, standardisierte Werte, logarithmiert) abgebildet. Komplexere geometrische Elemente basieren oft intern auf Datentransformationen (Säulendiagramme, geglättete Trendlinien, Boxplots)
- **Facettierung** definiert anhand welcher Merkmale die Daten in Subgruppen aufgeteilt werden und wie die Darstellungen der verschiedenen Subgruppen arrangiert werden (ggf. eigene Grafik für jede Teilgruppe sinnvoll)

Wahrnehmung von Grafiken

Wahrnehmungspsychologische Experimente zeigen deutliche Unterschiede in der korrekten Interpretation der folgenden Grafiktypen:




Abb.: Healy, K. (2018). *Data visualization: a practical introduction*. Princeton University Press. (übernommen aus Heer & Bostock)

Cleveland, W.S., McGill, R. (1984): *Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods*. *JASA* 79(387), 531-554.

Heer, J., Bostock, M. (2010): *Crowdsourcing graphical perception: using Mechanical Turk to assess visualization design*. *SIGCHI Proceedings*, 203-212.

Wahrnehmungs-Hierarchie für Informationscodierung:

1. Position (gemeinsame/parallele Skala "common scale" > verschobene Skalen)
2. Abstände und Größe/Längen
3. Steigung & Winkel
4. Flächen
5. Volumen und Dichte

6. Farbton-Farbsättigung-Farbhelligkeit

Da **Position und Abstände** am besten wahrgenommen werden, müssen diese für die Codierung der wichtigsten Merkmale verwendet werden.

Am leichtesten können Menschen horizontale Größenvergleiche einschätzen.

Generell sind daher Punkte-/Liniencharts oder Säulen-/Balkendiagramme immer Tortendiagrammen (winkelbasiert) vorzuziehen! Für wenige Informationen ist sogar eine Tabelle besser geeignet.

Mit Flächen(volumen) tun wir uns schwer.

Am schlechtesten funktionieren Farbvergleiche!

Multivariate Grafiken

Auch die schwächeren Darstellungsformen haben ihre Daseinsberechtigung, insbesondere als zusätzliche Informationsebene innerhalb einer hochrangigen 2D-Grafik (Limitierung auf zwei Dimensionen/Achsen erfordert weitere Codierungsformen für mehr Merkmale)

Farbe etwa eignet sich gut für kategorische (nominalskalierte/ordinale) Merkmale und hat den Vorteil, dass es mit allen anderen grafischen Elementen kombinierbar ist.

Anmerkungen zur optimalen Verwendung von statistischen Grafiken

- Geeignete klar beschriftete Achsen, (Gitterlinien), Geometrien, Ästhetiken, Gruppierung usw. wählen und immer die obige Wahrnehmungs-Hierarchie beachten!
 - Konsistente Einteilung von Achsen und Geometrie (selbes delta Abstand/Volumen/... sollte immer selbes ... bedeuten, proportional) und sinnvolle Seitenverhältnisse.
 - inhaltlich angemessene Reihenfolge/Sortierung der Ausprägungen von qualitativen Merkmalen
 - Glättung ("smoothing"): Bedacht umgehen mit durchgezogenen Linien zur Verbindung von Datenpunkten, die nicht-existente lineare Verläufe suggerieren. Es kann aber sinnvoll sein, wenn die Achse kleinteilig genug ist.
 - *Kommunikationsabsicht*: Es kommt stark darauf an, was man kommunizieren, was stark hervorheben und was man vergleichen möchte.
- Will man etwa Größe von zwei Kategorien/Gruppen prägnant vergleichen, sodass Leser den Wert direkt sieht, bieten sich zwei Säulen/Balken- mit unterschiedlichen Farben - nebeneinander an ("dodged barchart"). Möchte man aber in erster Linie prozentuale Anteile vermitteln, könnte es besser sein, nur eine Säule/Balken zu benutzen (Stapeldiagramm, "stacked barchart").
- Immer klar machen, wie genau die Information codiert ist, ggf. bei Verwirrungsgefahr extra Beschriftungen einfügen.
 - Informationen so klar, genau, effizient (maximale Infos) und kompakt wie möglich vermitteln!!
 - Lesbarkeit maximieren inkl. schneller Informationsvermittlung!
 - wahrhaftig, ohne Verzerrungen ##

John Rauser <https://www.youtube.com/watch?v=fSgEeI2Xpdc>

- time series is only useful if time is important for the analysis
- if growth matters just plot it directly
- categorial variables always have to be ordered to make the plot readable
- slopes: default or average should be around 45 degrees
- scatterplots are the best tool to visualize relationship between two metrics
- stacked charts are almost always a mistake and inferior to dotplots/line-charts on a common scale (exceptions are for instance development of shares over time)
- often its better to just create a second graphic instead of pressing too much information into a single one. If only one chart is possible, you should pick the "better", more meaningful one
- sometimes we use same scales for x-axis, but different one for y-axis in two different charts or within one chart (different lefthand and righthand vertical axis)
- very important: contrast between data and background, if grid lines are used make them pale so that they dont interfere with the data

Farbskalen

Es ist schwierig, anhand von Farben präzise Vergleiche abzulesen. Farbcodierungen sind dennoch allgegenwärtig, weil sie mit allen anderen grafischen Darstellungsformen *kombinierbar sind*. Farbe eignet sich etwa gut für kategorische (nominalskalierte/ordinale) Merkmale, die sonst nicht in derselben Grafik visualisierbar wären.

Farben für Grafiken sind so zu wählen dass **Wahrnehmungseinheitlichkeit** berücksichtigt wird:

- Verläufe über mehrere Farbtöne machen nur dann Sinn, wenn der Farbwechsel an qualitativ logischen Grenzen erfolgt (Farbton-Änderung sticht sonst irreführend heraus)
- Grün-/Gelbtöne werden bei gleicher Sättigung intensiver wahrgenommen als andere Farben
- Rot-Grün-Sehschwächen mitbedenken

Generell muss ausreichende Unterscheidbarkeit gewährleistet sein.

HCL-Farbraum (drei Dimensionen)

Farbton (*hue*): dominante Wellenlänge, kreisförmige Dimension

Farbsättigung (*saturation, chroma*)

Helligkeit (*brightness, luminance*)

Farbskalentypen

Qualitativ: Unterschiedlicher Farbton

(eher) nur für nominales Skalenniveau geeignet

Wahrnehmungseinheitlich, sehr gut unterscheidbare Codierung (manchmal gute, manchmal schlechte Eigenschaft – je nach Absicht des Grafikers)

Sequentiell:

erfordert mindestens ordinales Skalenniveau

- Bsp: konstanter Farbton und Helligkeit, variiere nur Sättigung

- oder Verlauf über mehrere Farbtöne mit variierender Sättigung und abnehmender Helligkeit (hier stechen Werte heraus, die mit sehr niedriger Helligkeit codiert werden)

Divergierend: Zwei sequentielle Skalen mit je konstantem Farbton werden kombiniert

erfordert mindestens ordinales Skalenniveau mit "neutralem" mittleren Wert, oberes und unteres Ende der Skala sticht besonders hervor

Beliebte divergierende Farbskalen sind "Veridis" (default in ggplot2), "Cividis" und "Magma"

Neutraler Wert per default als MW(Min, Max) oder MW(all values), kann man aber auch selber definieren.

Visualisierung der (relativen) Häufigkeiten diskreter/gruppierter Merkmale

Stabdiagramm: senkrechte Striche

Säulendiagramm: horizontale Rechtecke

Balkendiagramm: vertikale Rechtecke (sinnvoll z.B. bei viel Text für Merkmalsausprägungen, passt besser links neben y-Achse)

Anwendung: Nominale Merkmale (Problem: Anordnung der Ausprägungen beliebig!), metrische mit wenigen Ausprägungen und ordinale Merkmale.

⇒ zugeordnete Ästhetiken: Absolute/Relative Häufigkeiten als Höhe (y-Achse) dargestellt – jeweils für Merkmalsausprägungen (x-Achse), oder umgekehrt.

Geometrien: Vertikale/Horizontale Linien oder Rechtecke

Stapeldiagramm:

Darstellung der absoluten/relativen Häufigkeiten als Segmente unterschiedlicher Längen (Breiten). Die Abschnitte werden übereinander gestapelt und unterschiedlich eingefärbt.

Anwendung: Nominale Merkmale (aber wieder Reihenfolge-Problem), metrische Daten mit wenigen Ausprägungen, ordinale/gruppierende Merkmale

Besonders geeignet für den Vergleich verschiedener Gruppen durch nebeneinander liegende Stapel. Ergo bedingte Häufigkeiten gegeben Gruppe.

Relative Häufigkeit (Anteil) kann explizit oder nur implizit dargestellt sein.

⇒ zugeordnete Ästhetiken: Segmentlänge als absolute/relative Hkeiten der Merkmalsausprägungen optional: x- oder y-Position als Ausprägungen des bedingenden Merkmals

Geometrien: Vertikale oder horizontale Rechtecksegmente

Tortendiagramm, Kreisdiagramm:

Darstellung von relativen/absoluten Häufigkeiten als Anteile der Fläche eines Kreises.

Anwendung: Nominal, Ordinal (Problem: Ordnung nicht korrekt wiedergegeben), gruppiert.

Suboptimal: Darstellung über Längen » Darstellung über Winkel!

Im Prinzip ist Kreisdiagramm ein schlechteres Balkendiagramm im Polarkoordinatensystem, verbraucht auch mehr Platz.

Visualisierung der relativen Häufigkeiten und Verteilungen metrischer Merkmale

Dotplot (“Eindimensionales Streudiagramm”)

Darstellung der einzelnen Beobachtungen als Punkte (Breiten) entlang der Achse.

⇒ zugeordnete Ästhetiken: x-Position für beobachtete Merkmalsausprägungen der UE

optional: y-Position für Ausprägungen des bedingenden Merkmal, oder umgekehrt

verwendete Geometrien: Punkte bzw. Symbole

Scatterplot (“Zweidimensionales Streudiagramm”)

Klassisches Streudiagramm visualisiert den Zusammenhang zwischen zwei metrischen Merkmalen (bivariate metrische Daten).

Common problem with scatterplots is "**overplotting**": datapoints overlap with each other

Abhilfe schaffen könnte es, wenn man die Punkte verkleinert und/oder x- und y-Achse auseinanderzieht, also die Abstände und damit die gesamte Grafik vergrößert, um weniger Überlappungen bei den Datenpunkten zu haben.

=> gerade bei größeren Datenmengen besser mit halbdurchsichtigen (transparenten) Punkten/Symbolen arbeiten, um einzelne Datenpunkte klarer voneinander abzugrenzen.

Alternativ: Anzahl/Dichte direkt über Farbe codieren

Zusätzlichen Farbskala macht auch Sinn bei (diskreter/gruppierter/evtl. stetiger) Drittvariable, idealerweise bringt diese einen sinnvollen Mehrwert an Information.

Außerdem hätte man dieses Overplotting-Problem überhaupt nicht mit Facettierung, wenn man also für Farbkategorien einer Drittvariable oder andere Kategorien (halt nur nicht zu viele, sonst wird es zu arbiträr) jeweils ein eigenes Streudiagramm kreiert.

Bubble-Chart

Expansion of Scatterplot with area of point encoding amount of observations in that specific point/area (useful when data points tend to concentrate in certain areas – potentially for categories encoded with color)

Boxplot

Prägnante Visualisierung von Merkmalsverteilung, vor allem Quartilen und Median.

Auf einen Blick zu sehen: Min, Max, 25-50-75 Perzentile

Quartilsabstand (IQR): hier liegen "zentrale 50 Prozent" der Daten bei Ordinalskala
Streuung der mittleren 50 Prozent

unteres Quartil ($x_{0.25}$): Anfang der Box

oberes Quartil ($x_{0.75}$): Ende der Box

Quartilsabstand: Länge der Box


Median: markiert durch den Strich innerhalb der Box

Zwei Linien (whiskers) außerhalb der Box gehen bis zu Min und Max

Modifizierter Boxplot: Linien gehen nicht bis ganz nach draußen zu x_{min} und x_{max} , sondern nur bis zu gewisser Schwelle, üblicherweise Intervall $[x_{0.25} - 1,5 \cdot IQR, x_{0.75} + 1,5 \cdot IQR]$. Die restlichen Randwerte werden als reguläre Datenpunkte angezeigt.

Gruppierter Boxplot (zusätzliches Merkmal definiert Gruppen) => mehrere Plots

Man kann Höhe/Breite der einzelnen Boxplots proportional zur Gruppengröße visualisieren.



Boxplot Grammar of Graphics

Geometrie bei horizontaler (vertikaler) Version:

Rechteck mit vertikalem Band und horizontalen “whiskers”.

Zugeordnete Ästhetiken:

- horizontale (vertikale) Ausdehnung des Rechtecks: von x_{min} bis x_{max}

- horizontale Position des vertikalen Bands: x_{med}

- horizontale Positionen der Enden der “whiskers”: x_{min} bzw. x_{max}

► optional: vertikale Ausdehnung der Box: Anzahl der eingeflossenen Beobachtungen

Für modifizierten Boxplot zusätzlich:

- Geometrie “Punkte/Symbole” für Beobachtungen außerhalb der Schwellen


- entsprechend modifizierte Position der “whiskers”

Vorteile von Boxplots:

- kompakt, zentraler Bereich der Daten einfach ablesbar
- robust gegenüber Ausreißern, die auch schnell sichtbar sein
- Schiefe in Verteilung sichtbar

Nachteile:

- gegen Intuition (Viel Farbe - wenig Daten) da Ausreißer sehr prominent
- Multimodale Verteilungen nicht sichtbar



Anhand des Boxplots würde man gar nicht erkennen, dass es hier zwei Spitzen in der Verteilung gibt, die zudem auch noch verschieden stark ausfallen.

Boxplot für zwei Variablen: