

Paarvergleichsmaße: Kendall's Tau

Betrachte Paare von Beobachtungen (x_i, y_i) und (x_j, y_j)

Ein Paar heißt:

konkordant, falls $x_i < x_j$ und $y_i < y_j$
oder $x_i > x_j$ und $y_i > y_j$,
also: Rangfolge der X-Werte gleich der der Y-Werte.

diskordant, falls $x_i < x_j$ und $y_i > y_j$
oder $x_i > x_j$ und $y_i < y_j$,
also: Rangfolge der X-Werte umgekehrt der Y-Werte.


N_C : Anzahl der konkordanten Paare

N_D : Anzahl der diskordanten Paare

Insgesamt $n(n - 1)/2$ mögliche Paare.

Kendall's Tau:
$$\tau_{xy} = \frac{N_C - N_D}{n(n - 1)/2}$$

Kendall's Tau: Veranschaulichung



Varianten

- ▶ Goodman & Kruskal γ -Koeffizient ignoriert Paare mit Bindungen:

$$\gamma_{xy} = \frac{N_C - N_D}{N_C + N_D}$$

- ▶ Somers' D wird typischerweise verwendet wenn Y binär ist
($\Rightarrow$ viele Paare mit Bindungen in Y)

$$D_{xy} := \frac{N_C - N_D}{\text{Anzahl Paare mit ungleichem } y}$$

Unterschiede Kendall's τ_{xy} , Spearman's r_{xy}^{SP}

- ▶ r_{xy}^{SP} verwendet Abstände auf der Rang-Skala
- ▶ τ_{xy} orientiert sich an Paarvergleichen
- ▶ τ_{xy} ist in der Regel betragsmäßig kleiner als r_{xy}^{SP}

Distanzkovarianz & Distanzkorrelation

Modernes Zusammenhangsmaß für (fast) beliebige Zusammenhänge (nicht nur linear/monoton).

Basiert auf Produkten der (zentrierten) Distanzen der Beobachtungen untereinander, nicht nur auf Distanzen zu ihren Mittelwerten.

Distanzkovarianz dS_{xy} :

$$dS_{xy} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n D_{ij}^x D_{ij}^y$$

- ▶ zentrierte Distanzen $D_{ij}^x = d_{ij}^x - (\bar{d}_{i\cdot}^x + \bar{d}_{\cdot j}^x - \bar{d}^x)$ mit
- ▶ $d_{ij}^x = |x_i - x_j|$
- ▶ $\bar{d}_{i\cdot}^x = \frac{1}{n} \sum_{j=1}^n d_{ij}^x$ und $\bar{d}_{\cdot j}^x = \frac{1}{n} \sum_{i=1}^n d_{ij}^x$,
- ▶ $\bar{d}^x = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n d_{ij}^x$
- ▶ analog für D_{ij}^y

Distanzkorrelation

Die **Distanzkorrelation** ist definiert als

$$dr_{xy} = \sqrt{\frac{dS_{xy}^2}{\sqrt{dS_{xx}^2 dS_{yy}^2}}}$$

wobei

- ▶ $dS_{xy}^2 = dS_{xy} dS_{xy}$
- ▶ dS_{xx} ist die Distanzkovarianz von X mit sich selbst.

Eigenschaften Distanzkorrelation

- ▶ $0 \leq dr_{xy} \leq 1$ – misst nur Stärke, nicht “Richtung” der Abhängigkeit.
- ▶ $dr_{xy} = 0$ genau dann wenn X und Y empirisch unabhängig sind (!)
- ▶ $dr_{xy} = 1$ für perfekt lineare Zusammenhänge (bei Verwendung der euklidischen Distanz)
- ▶ **Sehr** allgemein anwendbar:
 - ▶ beliebige Distanzmaße verwendbar als d_{ij}^x, d_{ij}^y
 - ▶ → auch für alle *multivariaten* oder *nicht-numerischen* Daten X, Y (z.B. Bilder, Audiosignale, Gensequenzen,) benutzbar, für die man jeweils Distanzen definieren kann.

