

Kovarianz

Kennzahl für Stärke und Richtung des linearen Zusammenhang zweier metrischer Merkmale:


Daten: $(x_i, y_i), i = 1, \dots, n$

$$S_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$


Beachte:

- ▶ Summand i positiv, falls Abweichungen von x_i und y_i zum jeweiligen Mittelwert das gleiche Vorzeichen haben, negativ falls unterschiedlich.
- ▶ Für S_{xx} ergibt sich die Varianz von X : $S_{xx} = S_x^2$
- ▶ Der Wert der Kovarianz hängt sowohl von der **Größe der Streuungen** als auch von der **Stärke und Richtung des Zusammenhangs** der beiden Merkmale ab.


Kovarianz: Geometrische Intuition



Kovarianz: Geometrische Intuition



Kovarianz: Geometrische Intuition



$$S_x^2 = 70, S_y^2 = 19600, S_{xy} = 505, r_{xy} = 0.43$$

Bravais-Pearson-Korrelationskoeffizient

Der Bravais-Pearson-Korrelationskoeffizient r_{xy} ergibt sich aus den Daten $(x_i, y_i), i = 1, \dots, n$ durch

$$\begin{aligned} r_{xy} &= \frac{1}{n-1} \sum_{i=1}^n \frac{(x_i - \bar{x})}{S_x} \frac{(y_i - \bar{y})}{S_y} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{S_{xy}}{S_x S_y} \end{aligned}$$

Wertebereich: $-1 \leq r_{xy} \leq 1$

► dimensionslose Größe, hängt nicht mehr von S_x oder S_y ab:







- $r_{xy} > 0$ positive Korrelation, gleichsinniger linearer Zusammenhang, Tendenz: Werte (x_i, y_i) um eine Gerade positiver Steigung liegend
- $r_{xy} < 0$ negative Korrelation, gegenläufiger linearer Zusammenhang, Tendenz: Werte (x_i, y_i) um eine Gerade negativer Steigung liegend
- $r_{xy} = 0$ keine Korrelation, unkorreliert, kein linearer Zusammenhang

Eigenschaften des Korrelationskoeffizienten


- ▶ Misst vor allem die Stärke des **linearen** Zusammenhangs
- ▶ Betrag der Korrelation unverändert bei linearen Transformationen
- ▶ Symmetrisch: $r_{xy} = r_{yx}$
- ▶ Positive Korrelation bedeutet:
“Je größer X, desto größer im Durchschnitt Y”
- ▶ Korrelation = +1 [-1] falls die Punkte genau auf einer Geraden mit positiver [negativer] Steigung liegen – **unabhängig von Steigung dieser Geraden** (außer sie ist 0 oder ∞).
- ▶ “Korrelation = 0” bedeutet “kein *linearer* Zusammenhang”, aber **nicht Unabhängigkeit!** (s. Bsp. unten)
- ▶ Korrelation (und Kovarianz) sind empfindlich gegenüber Ausreißern

Eigenschaften von r_{xy}

Misst nur Stärke des **linearen** Zusammenhangs:



Eigenschaften Bravais-Pearson-Korrelation



Alle diese Datensätze haben $r_{xy} = -0.06$!

(und $n = 142$, $\bar{x} = 54.3$, $S_x = 16.8$, $\bar{y} = 47.8$, $S_y = 26.9$)

Lineare Transformationen

- ▶ Bei exakten linearen Zusammenhängen gilt:

$$r_{xy} = +1 \text{ bzw. } -1 \quad \Longleftrightarrow \quad Y = aX + b \text{ mit } a > 0 \text{ bzw. } a < 0$$

- ▶ Lineare Transformationen $\tilde{X} = a_X X + b_X, \tilde{Y} = a_Y Y + b_Y, a_X, a_Y \neq 0$:
 r_{xy} Korrelationskoeffizient zwischen X und Y
 $\tilde{r}_{xy}$ Korrelationskoeffizient zwischen $\tilde{X}$ und $\tilde{Y}$

$$\begin{aligned} \Rightarrow \quad \tilde{r}_{xy} &= r_{xy} && \Longleftrightarrow && a_X, a_Y \text{ gleiches Vorzeichen} \\ \tilde{r}_{xy} &= -r_{xy} && \Longleftrightarrow && a_X, a_Y \text{ verschiedene Vorzeichen.} \end{aligned}$$