

Das Gesetz der großen Zahlen (Satz 11.10) und der Zentrale Grenzwertsatz (Satz 12.5) sind zwei der herausragendsten Resultate der Statistik. Ersteres erlaubt es uns den Erwartungswert $\mathbb{E}[X]$ einer zufälligen Größe über den Mittelwert $n^{-1} \sum_{i=1}^n X_i$ von (iid) Stichproben $X_i \sim X$ zu schätzen. Der zentrale Grenzwertsatz lässt uns dann die Unsicherheit dieser Schätzung quantifizieren:

$$\frac{1}{n} \sum_{i=1}^n X_i \stackrel{D}{\approx} \mathcal{N}(\mathbb{E}[X], n^{-1} \text{Var}[X]).$$

Der Satz von Berry-Esseen (Satz 12.8) erlaubt uns sogar für *endliche* Stichproben zu argumentieren. Eine sehr schöne Illustration des Zentralen Grenzwertsatzes (engl: central limit theorem; kurz CLT) findet ihr hier.

Aufgabe 1

Sei $f : \mathbb{R} \rightarrow \mathbb{R}$ eine stetige Dichtefunktion (d.h. $P(A) = \int_A f d\lambda$ definiert ein Wahrscheinlichkeitsmaß auf $\mathbb{R}$). Seien $X_i \sim f$ iid. Für den Bandbreiten Parameter $h > 0$ definiere den Dichte Schätzer mit uniformen Kern

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{2h} 1\{|X_i - x| \leq h\}$$

wobei $1\{|X_i - x| \leq h\} = 1$ für $|X_i - x| \leq h$ und 0 sonst. Sei $x \in \mathbb{R}$ fix.

1. Nutze das (schwache) Gesetz der großen Zahlen um $\hat{f}(x) \xrightarrow{\mathbb{P}} \mathbb{E}[\hat{f}(x)]$ zu zeigen.
2. Nutze den zentralen Grenzwertsatz um

$$\sqrt{n}(\hat{f}(x) - \mathbb{E}[\hat{f}(x)]) \stackrel{D}{\rightarrow} \mathcal{N}(0, \text{Var}((2h)^{-1} 1\{|X_1 - x| \leq h\})).$$

3. Berechne $\mathbb{E}[\hat{f}(x)] = \frac{\mathbb{P}(X_1 \leq x+h) - \mathbb{P}(X_1 \leq x-h)}{2h}$.
4. Berechne $\text{Var}[\hat{f}(x)] = \frac{\mathbb{E}[\hat{f}(x)](1 - 2h\mathbb{E}[\hat{f}(x)])}{2nh}$.
5. Nimm nun an, dass f stetig differenzierbar ist. Welchen Einfluss hat h auf den Bias $\mathbb{E}[\hat{f}(x)] - f(x)$ bzw. $\text{Var}[\hat{f}(x)]$?

Lösung: Weil X_i iid sind, sind auch $Y_i = (2h)^{-1} 1\{|X_i - x| \leq h\}$ iid Zufallsvariablen. 1. und 2. folgen damit direkt aus dem Gesetz der großen Zahlen und dem zentralen Grenzwertsatz. Es gilt $\mathbb{E}[1\{|X_i - x| \leq h\}] = \mathbb{P}(|X_i - x| \leq h) = \mathbb{P}(X_1 \leq x+h) - \mathbb{P}(X_1 \leq x-h)$ per Definition und weil X_i identisch verteilt sind. Da $\mathbb{E}$ linear ist, folgt 3. Da X_i unabhängig sind, sind auch $1\{|X_i - x| \leq h\}$ unabhängig. Es folgt

$$\text{Var}[\hat{f}(x)] = n^{-1} \text{Var}[Y_1] = \frac{1}{(2h)^2 n} \text{Var}[1\{|X_1 - x| \leq h\}]$$

Bemerke, dass $1\{|X_i - x| \leq h\}$ diskrete Zufallsvariablen sind die nur den Wert 1 und 0 annehmen. D.h. $1\{|X_i - x| \leq h\}$ sind Bernoulli verteilt mit

$$\text{Var}[1\{|X_i - x| \leq h\}] = \mathbb{P}(1\{|X_i - x| \leq h\} = 1)(1 - \mathbb{P}(1\{|X_i - x| \leq h\} = 1)).$$

Wir berechnen $\mathbb{P}(1\{|X_i - x| \leq h\} = 1) = \mathbb{E}(1\{|X_i - x| \leq h\} = 1) = 2h\mathbb{E}[\hat{f}(x)]$. Zusammen erhalten wir 4.

Schreibe $F(x) = \mathbb{P}(X_1 \leq x)$. Es gilt $\frac{d}{dx}F(x) = f(x)$. Eine Taylorapproximation um x liefert

$$F(x+h) = F(x) + hf(x) + \mathcal{O}(h^2)$$

für $h \rightarrow 0$. In anderen Worten,

$$\mathbb{E}[\hat{f}(x)] - f(x) = \frac{F(x+h) - F(x-h)}{2h} - f(x) = \mathcal{O}(h^2).$$

D.h. der Bias $\mathbb{E}[\hat{f}(x)] - f(x)$ geht gegen 0 für $h \rightarrow 0$. Auf der anderen Seite gilt

$$\text{Var}[\hat{f}(x)] = \mathcal{O}((hn)^{-1}),$$

d.h. die Varianz geht gegen ∞ für $h \rightarrow 0$.

Bonus: Da wir explizite Ordnungen haben, können wir den Bias-Varianz trade-off in Abhängigkeit von n berechnen. In anderen Worten, wir suchen $h = h_n$ s.d. der erwartete quadratische Abstand

$$\mathbb{E}[(\hat{f}(x) - f(x))^2] = \underbrace{(\mathbb{E}[\hat{f}(x)] - f(x))^2}_{\text{bias}} + \underbrace{\text{Var}[\hat{f}(x)]}_{\text{variance}}$$

schnellstmöglich gegen 0 geht. Wegen $\text{Var}[\hat{f}(x)] \lesssim (hn)^{-1}$ und $\mathbb{E}[\hat{f}(x)] - f(x) \lesssim h^2$ bestimmen wir das Minimum von $1/(hn) + h^4$ in Abhängigkeit von n . Das liefert $h = n^{-1/5}$ und wir erhalten die optimale Rate

$$\mathbb{E}[(\hat{f}(x) - f(x))^2] = \mathcal{O}(n^{-4/5}).$$

Aufgabe 2

Sei $\Omega = \{0, 1\}$ versehen mit der Potenzmenge als σ -Algebra und Maß $\mathbb{P}(\{0\}) = \mathbb{P}(\{1\}) = 1/2$. Definiere $X_n, X : \Omega \rightarrow \mathbb{R}$, $X(1) = X_n(0) = 0$ und $X(0) = X_n(1) = 1$. Zeige:

1. $\mathbb{P}(X_n \leq t) = \mathbb{P}(X \leq t)$.
2. $\mathbb{P}(|X_n - X| > 1/2) = 1$ für alle n .
3. Folgere $X_n \xrightarrow{D} X$ aber $X_n \not\xrightarrow{\mathbb{P}} X$.

Lösung: 1. und 2. folgen direkt aus der Konstruktion. Wegen 1. folgt $X_n \xrightarrow{D} X$. Wegen 2. folgt $X_n \not\xrightarrow{\mathbb{P}} X$.

Aufgabe 3

Sei X_n eine Sequenz von Zufallsvariablen mit $X_n \xrightarrow{D} c$ wobei $c \in \mathbb{R}$ ein Skalar ist. Zeige: $X_n \xrightarrow{\mathbb{P}} c$.

Lösung: Es gilt

$$\mathbb{P}(|X_n - c| > \varepsilon) = 1 - \mathbb{P}(|X_n - c| \leq \varepsilon) = 1 - \mathbb{P}(X_n \leq \varepsilon + c) - \mathbb{P}(X_n < c - \varepsilon).$$

Wegen $X_n \xrightarrow{D} c$ erhalten wir $\mathbb{P}(X_n \leq \varepsilon + c) \rightarrow \mathbb{P}(c \leq \varepsilon + c) = 1$ und $\mathbb{P}(X_n < \varepsilon - c) \rightarrow \mathbb{P}(c < c - \varepsilon) = 0$ für alle $\varepsilon > 0$. Es folgt $\mathbb{P}(|X_n - c| > \varepsilon) \rightarrow 0$ für alle $\varepsilon > 0$ und damit die Behauptung.

Aufgabe 4

Sei $c \in \mathbb{R}$ und X_n eine Sequenz von Zufallsvariablen s.d. $\sqrt{n}(X_n - c) \xrightarrow{D} X$. Zeige: $X_n \xrightarrow{\mathbb{P}} c$.
Hinweis: nutze die vorherige Aufgabe und Slutsky (Satz 12.4).

Lösung: Bemerke $1/\sqrt{n} \rightarrow 0$. Aus dem Satz von Slutsky folgern wir

$$(X_n - c) = 1/\sqrt{n}(\sqrt{n}(X_n - c)) \xrightarrow{D} 0X = 0.$$

Mit Aufgabe 3. folgt $X_n \xrightarrow{\mathbb{P}} c$.