i.i.d-Modell | Betrachten i.i.d. ZV $X_1, \dots, X_n$ also unabhängig und identisch verteilt

Standardsituation, wenn $X_1, \dots, X_n$ Stichprobe eines Merkmals X bei einer einfachen Zufallsauswahl sind

- Familie von ZV $X_i: \Omega \to \Omega_i$ stochastisch unabh. und haben alle dieselbe Verteilung $X_i \sim \mathbb{D}$
- Weitere Annahme ist Existenz von Erwartung μ und Varianz σ^2

Messbare Transformation: X_i i.i.d., $g: \mathbb{R} \to \mathbb{R}$ messbare Fkt. $\xrightarrow{\text{weiterhin LLN gilt}} \frac{1}{n}\sum_{i=1}^{n} g(X_i) \xrightarrow{\mathbb{P}} \mathbb{E}(g(X_i))$

Schwaches Gesetz der großen Zahlen

Seien $X_1, \dots, X_n$ i.i.d. mit $\mathbb{E}(X_i) = \mu$ und $\mathrm{Var}(X_i) = \sigma^2 < \infty \ \forall i \in \{1, \dots, n\}$

Dann $\overline{X}_{(n)} = \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{\mathbb{P}} \mu$

sample mean $\xrightarrow{n\to\infty}$ E.V

ZV, deren Realisation der MW von allen Stichproben-Werten ist, konvergiert für $n \to \infty$ gegen Erwartungswert in Wkeit

Analog: Empirischer MW geht für $n \to \infty$ gegen wahren MW / wahren Wert, allgemeiner aus datengenerierender Verteil.

Siehe CLT $f(\overline{X})$ mit $n \uparrow$ wird $f(\overline{X})$ immer enger um EV μ_X und Histogramm/Kernddichteschätzer nähert sich zunehmend Normalverteilung an

$\mathbb{E}(\overline{X}) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}(X_i) \overset{\text{i.i.d.}}{=} \frac{1}{n}\cdot(n\mu) = \mu$ (E linear) $\quad \mathrm{Var}(\overline{X}_n) = \frac{1}{n}\sigma^2 \xrightarrow{\mathbb{P}} 0$

$\mathbb{E}(|\overline{X} - \mu|^2) = \mathrm{Var}(\overline{X}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) \overset{\text{i.i.d. } \mathrm{cov}(\cdot)=0 \text{ wegen } \perp}{=} \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}\cdot n\sigma^2 = \frac{1}{n}\sigma^2 \xrightarrow{\text{konv. im 2. Moment}} 0$ für $\sigma^2 < \infty$ $\Rightarrow$ auch im 1. Mom. $\mathbb{E}(|\overline{X}-\mu|) \to 0 \Rightarrow X \xrightarrow{\mathbb{P}} \mu$ (stärkere Konvergenz)

Tatsächlich ist nur endlicher EV $\mathbb{E}(X_i) = \mu < \infty$ notwendig. $\mathrm{Var}(X_i) = \sigma^2 < \infty$ ermöglicht eleganten Beweis, aber ist nicht erforderlich.

Deshalb funktioniert schwaches LLN für $X_i \sim t(2)$ t-Verteilung mit 2 FG, die EW u. keine Var hat vs. nicht bei Cauchy-Verteilung, die nichtmal EW besitzt.

Spezialfall: n Bernoulli-Experimente mit Erfolgswahrscheinlichkeit π. $X_i \sim B(1, \pi)$

Relative Häufigkeit der Erfolge ($\overline{X}$) konvergiert gegen wahre Wahrscheinlichkeit $\overline{X}_n \xrightarrow{\mathbb{P}} \pi$

, Grundprinzip von Monte-Carlo-Sims basiert auf LLN
Frequentistischer E.V $\triangleq$ Grenzwert des MW
Frequentistische Wkeit $\triangleq$ Grenzwert d. relativen Hkeit

LLN "Law of Large Numbers"

Starkes Gesetz der großen Zahlen

$X_1, \dots, X_n$ i.i.d. ZV. Existiert E.V $\mathbb{E}(X_1)$ und endlich also $\mathbb{E}(|X_1|) < \infty$

dann gilt $\overline{X}_{(n)} = \frac{1}{n}\sum_{i=1}^{n} X_i$ konvergiert IP-fast-sicher für $n \to \infty$ gegen Erwartungswert mit $\lim_{n\to\infty} \overline{X} = \mathbb{E}(X_1)$

Ist $\mathbb{E}(X_1) = \infty \Rightarrow \overline{X}$ konvergiert IP-fast-sicher NICHT gegen endlichen Erwartungswert

Beide verallgemeinert] ZV-Folge $(X_n)_{n\in\mathbb{N}}$ mit $\mathbb{E}(|X_n|) < \infty \ \forall n \in \mathbb{N}$ genügt starkem (schwachem) LLN, wenn $\overline{X}_n^C := \frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}(X_i)) \xrightarrow{\text{f.s. (IP)}} 0$ (Folge der zentrierten MW)

Zwei Gesetze, die KEINE identische Verteilung der X_i erfordern ↳ nicht derselbe Erwartungswert & Varianz

Keine direkte Abh. der X_i z.B. nur Abh. zwischen Gruppen

* es reicht sogar paarweise Unabhängigkeit bei identischer Verteilung (für abhängige ZV gibt es Ergodensätze, siehe stochastische Prozesse)

- Kolmogorov-Bedingung: Wenn $\sum_{n=1}^{\infty}\frac{\mathrm{Var}(X_n)}{n^2} < \infty$ so genügt ZV-Folge dem starken LLN
- Satz von Cantelli: Wenn X_n endliche 4. Momente $\forall n \in \mathbb{N}$ hat und zentrierte 4. Momente gleichmäßig beschränkt $\sup_{n\in\mathbb{N}} \mathbb{E}((X_n - \mathbb{E}(X_n))^4) < \infty$ so genügt sie starkem LLN

LLN erlaubt es uns unbekannten Erwartungswert $\mathbb{E}(X) = \mu$ einer zufälligen Größe über MW von i.i.d. Stichproben $X_i \sim X$ zu schätzen. CLT quantifiziert Unsicherheit / Verteilung dieser Schätzung

Zentraler Grenzwertsatz

CLT "Central Limit Theorem" impliziert LLN und besagt, dass sample average approx. normalverteilt um E.V ist (darum NV so wichtig in Statistik!)

X_i i.i.d. mit $\mathbb{E}(X_i) = \mu$ und $\mathrm{Var}(X_i) = \sigma^2 < \infty \ \forall i$

ZV: $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$

, ZV/Schätzer: $S_X^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$

, genauso kann man auch nur $\overline{X}$ betrachten, das gegen μ geht

uns interessiert Verteilung von $\overline{X} - \mu$, was laut LLN f.s. gegen 0 konvergiert

$\overline{X}$ zentriert: $(\overline{X} - \mu) \xrightarrow{\mathbb{D}} N(0, \sigma^2/n)$ $\Leftrightarrow \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu) \overset{a}{\sim} N(0, \sigma^2)$ typische Abweichungen von $\overline{X}$ zu EW/μ in Größenordnung $1/\sqrt{n}$

Dann $\frac{\sqrt{n}(\overline{X}-\mu)}{\sigma} \xrightarrow{\mathbb{D}} N(0,1)$ bzw. $\sqrt{n}(\overline{X} - \mu) \xrightarrow{\mathbb{D}} N(0, \sigma^2)$ für $n \to \infty$, $\sqrt{n} \triangleq$ Konvergenzgeschwindigkeit

Z_n ($\overline{X}$ standardisiert) $\quad \cdot\sigma$ rein $\leftrightarrow$ rausdividieren

$\Leftrightarrow \overline{X} \xrightarrow{\mathbb{D}} N(\mu, \sigma^2/n)$

$SD(\overline{X}_n) = \sigma/\sqrt{n}$ ↑ erhöht Genauigkeit als Vorfaktor weil $\mathrm{Var}(\overline{X}_n) = \sigma^2/n$ $\quad \mathrm{Var}(\overline{X}_n) = \mathrm{Var}\left(\frac{1}{n}\sum X_i\right) = \frac{1}{n^2}\mathrm{Var}(\Sigma\dots) = \frac{1}{n}\sigma^2$, $\mathrm{Var}(\Sigma X_i) = n\sigma^2$

$\Leftrightarrow Y_n \xrightarrow{\mathbb{D}} N(\mu^S, \sigma_X^2 n)$

Y_n zentriert: $(Y_n - \mu^S) \xrightarrow{\mathbb{D}} N(0, \sigma_X^2 n)$

Wenn Summe statt MW interessiert, also Verteilung von $\sum_{i=1}^{n} X_i = Y_n$: $\frac{Y_n - \mu^S}{\sqrt{n}\sigma_X} \sim N(0,1)$, $\frac{1}{\sqrt{n}}$ von MW-Berechnung fehlt $\mathrm{Var}(Y_n) = \sigma^2 n$ $\quad SD(Y_n) = \sigma\sqrt{n}$

Neuer Erwartungswert logischerweise $\mu^S = n \cdot \mu_X$ (Y_n standardisiert) $\quad \frac{1}{\sqrt{n}}\sum_{i=1}^{n}\frac{X_i - \mu_X}{\sigma_X} \overset{a}{\sim} N(0,1)$ Streuung ↑ mit n, aber wird rel. kleiner vs. $\mu^S = n\mu$

Durch Zentralen Grenzwertsatz können viele (unbekannte) Verteilungen durch NV (oder davon abgeleitete Verteilungen) approximiert werden! diskrete u. stetige

Auch für endliche Stichproben (kein $n \to \infty$) können wir mit Einschränkung über CLT argumentieren, Korrektur wichtiger bei schiefen Verteilungen u.a. Faktor $\frac{\mu^S}{\sqrt{n}}$

$n \uparrow\uparrow \Rightarrow$ Schiefe egal

Schreibweise für diese asymptotische Aussage: $\sim$ oder $\overset{a}{\sim}$

Bsp. i) Würfel diskrete Gleichverteilung $X_i \sim U(1,2,3,4,5,6)$, $\mathbb{E}(X_i) = 3.5$ $\mathrm{Var}(X_i) = \frac{6^2-1}{12} = 35/12$ für $n \to \infty$ approx. $\sqrt{n}\frac{\overline{X} - 3.5}{\sqrt{35/12}} \overset{a}{\sim} N(0,1)$

Bernoulli-Verteilung

ii) $X_i \sim B(1,p)$, $Y_n = \sum_{i=1}^{n} X_i \sim B(n,p)$ für $n \to \infty$ approx. $\frac{Y_n - np}{\sqrt{n}\sqrt{p(1-p)}} \overset{a}{\sim} N(0,1)$ bzw. $Y_n \overset{a}{\sim} N(np, n\cdot p(1-p))$

$\overline{X} = \frac{Y_n}{n} \sim N\left(p, \frac{p(1-p)}{n}\right) \Longrightarrow \mathbb{P}\left(p - 1.96\sqrt{\frac{p(1-p)}{n}} \le \frac{Y_n}{n} \le p + 1.96\sqrt{\frac{p(1-p)}{n}}\right) \approx 0.95$ konkret mit 0.025-Quantil von Standard-NV ≈ 1.96

$\mathrm{Var}\left(\frac{Y_n}{n}\right) = \frac{1}{n^2}\mathrm{Var}(Y_n)$

Vorsicht: F_{X_i} darf ohne zusätzliche Annahmen nicht von n abhängen!

iii) i.i.d. $X_i \sim Po(\frac{1}{n})$ $\sum_{i=1}^{n} X_i \sim Po(1)$ gut Versch. Approx. $\sqrt{n}\frac{(\overline{X} - 1/n)}{\sqrt{1/n}} \overset{\text{raus}}{=} \frac{\sum_{i=1}^{n} X_i - n\cdot\frac{1}{n}}{\sqrt{n}} = \frac{\sum X_i - 1}{1} \sim Po(1) - 1 \overset{a}{\sim} N(0,1)$

Hauptsatz der Statistik

(ECDF) empirische Verteilungsfkt. von $X_1, \dots, X_n$ i.i.d. $\quad \hat{F}(x) = \frac{1}{n}\sum_{i=1}^{n} I_{(-\infty, x]}(X_i)$

⟨diese müssen existieren, aber keine Momente vs. LLN & CLT⟩

i) $\hat{F}(x) \xrightarrow{\text{f.s.}} F(x) \ \forall x \in \mathbb{R}$ punktweise

Fundamentalsatz erlaubt Schätzung v. "wahren" theoretischen Verteilungen aus hinreichend großen Stichproben

funktioniert sogar bei Cauchy-Verteilung

ii) $\sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{\mathbb{D}} N(0, F(x)\cdot(1-F(x))) \ \forall x \in \mathbb{R}$ bzw. 'Ableitung' also Dichte schätzen mit Histogramm / Kernddichte

iii) $\sup|\hat{F}_n(x) - F(x)| \xrightarrow{\text{f.s.}} 0$ Max. Abweichung zw. ECDF und 'wahrem' $F \xrightarrow{n\to\infty} 0$

$I_{X_i \le x} \sim B(1, F(x))$ i.i.d. $\quad$ $\mathrm{Var}(n\text{-mal Bernoulli})$, x liegt im Intervall von $F(x)$ oder nicht $\quad$ Wkeiten $\triangleq$ rel. Häufigkeit