

Univariate statistische Kennwerte

Lagemaßzahlen

→ Wo liegt „Mitte“ der beobachteten Werte, wo ist Konzentration / Dichte besonders hoch?

→ Welche Merkmalsausprägung ist „typisch“ für dieses Merkmal? [m] diskret: x -Wert mit höchstem $n(x)$ für ein $\epsilon > 0$

[x_{mod}]

MODUS Definition: Häufigster Wert **Wichtigstes Lagemaß für kategoriale Merkmale** → Modi sind lokale Max. stellen der Dichtefunktion

Voraussetzungen: geeignet für alle Skalenniveaus, aber nur bei gruppierten Daten oder Merkmalen mit wenigen Ausprägungen sinnvoll

Eigenschaften: direkt übertragbar bei guten eindeutigen Transformationen

(In ECDF: Größte Sprungstelle von $F(x)$)

Nachteile: oft nicht eindeutig, in der Praxis meist sehr geringer Informationsgehalt

MEDIAN Definition: Exakte Mitte der Daten (geordnete Werte $x_{(1)}, x_{(2)}, \dots, x_{(n)}$)

Voraussetzung: mindestens ordinalskaliert

Mindestens 50 Prozent der Werte sind kleiner / größer oder gleich $\tilde{x}_{med}$ → teilt Beobacht. in zwei gleichgroße Hälften

ZV: Mitte der Verteilung, Mitte der Dichtekurve (teilt in zwei flächengleiche Hälften) bzw. Wertschwer

(In ECDF: Wo $F(x) = 0.5$ erreicht)

Berechnung: für n ungerade genau in der Mitte, für n gerade = $1/2 \cdot (\text{Summe der beiden mittigsten Werte})$ bei stetigen Merkmalen

Ordinalskala: $\{x_i\}, \{x_j\}$ formal korrekt

Formal als Minimierungsproblem: $\tilde{x}_{med} = \arg \min_x \sum_{i=1}^n |x_i - x|$ "Wert, der Summe der abs. Differenzen zu beobachteten Werten minimiert"

Eigenschaften: direkt übertragbar bei monotonen Transformationen (Rangfolge bleibt erhalten)

Vorteile: Anschaulich, robust gegenüber extremen Werten

Nachteil: Unpräzise

Stetige ZV: $\int_{-\infty}^q f(x) dx = p, \int_p^{\infty} f(x) dx = 1-p$

reelle Zahl q mit $P((-\infty, q]) \geq p$ und $P((q, \infty)) \geq 1-p$

Für stetige ZV mit str. monoton steigender Verteilungsfkt. ($f(x) \geq 0$) gilt: $\tilde{x}_p = F^{-1}(p)$ "Quantilkt. von X "

für stetige ZV: $\tilde{x}_p = F^{-1}(p)$

Quantile von ZV: p als Wahrscheinlichkeit $\Rightarrow \tilde{x}_p$ ist kleinster Wert, der mindestens mit Wk p unterschritten wird

Formal: $\tilde{x}_p = \arg \min_{x \in \mathbb{R}} \{x: F(x) \geq p\}$

QUANTIL Definition: Für p -Quantil $\tilde{x}_p$ gilt

$p \in [0, 1]$

mindestens Anteil p der Daten sind kleiner oder gleich $\tilde{x}_p$

mindestens Anteil $1-p$ der Daten sind größer oder gleich $\tilde{x}_p$

$\tilde{x}_p = p$ für $X \sim U[0, 1]$

! In R existiert 9 Typen von Quantilen mit leicht unterschiedlicher Definition, die sich jedoch nur für extreme Quantile sichtbar unterscheiden.

Eine Berechnungsmethode: $n \cdot p \in \mathbb{Z} \vee, n \cdot p \notin \mathbb{Z} \rightarrow$ Zahl aufrunden (obere Gauß-Klammer)

p -Quantil $\equiv (100 \cdot p)$ -Perzentil

$\tilde{x}_{0.25} \equiv$ unteres Quartil / $\tilde{x}_{0.75} \equiv$ oberes Quartil

IQR = $\tilde{x}_{0.75} - \tilde{x}_{0.25}$ (Inter-Quartile-Range)

Boxplot enthält zusätzlich noch x_{min}, x_{max}

Quartilsabstand Δ Streuung der mittleren 50 Prozent

Median ist das 0.5-Quantil bzw. 50-Perzentil

(egal wie extrem draußen Wert liegt, fällt nicht auf)

def. Bereich der zentralen 50% bei Ordinalskala

Median-Vorteile, also Resistenz vs. Extremwerten oben/unten, gilt für Quantile allgemein, kann aber auch Analyse-Zielen widerstreben.

MITTELWERT (arithmetisches Mittel)

Definition: Schwerpunkt der Daten bekanntestes Lagemaß

empirisches Pendant zu $E(X)$

1 Durchschnitt

gut für "additive" Skalen, auf denen absolute Unterschiede relevant sind

Berechnung: $\bar{x} = 1/n \sum_{i=1}^n x_i \rightarrow \sum_{i=1}^n (x_i - \bar{x}) = 0!$

Voraussetzung: Intervallskala

Formal als Minimierungsproblem: $\bar{x} = \arg \min_x \sum_{i=1}^n (x_i - x)^2$ "Wert, der Summe d. quadrierten Differenzen zu beob. Werten minimiert"

MW bei gruppierten Daten: $\bar{x} = 1/n \sum_{j=1}^k h_j a_j = \sum_{j=1}^k f_j \cdot a_j$

Gewichteter MW: $\bar{x}_W = \frac{1}{\sum_{i=1}^n w_i} \sum_{i=1}^n w_i x_i$ Gewichte w_i addieren sich zu 1

h_j : Hkkeit von a_j ; $1/n \cdot h_j$: relative Hkkeit

Lineare Transformation des Mittels: $y_i = a + b x_i \Rightarrow \bar{y} = a + b \bar{x}$, also $a + b \bar{x} = a + b \bar{x}$ (egal, ob man erst MW berechnet oder transformiert)

↳ $L(\bar{x}) = L(\bar{y})$ ✓, aber generell für alle Transformation gilt das nicht! $y_i = 11 x_i \Rightarrow \bar{y} = 11 \bar{x}$

MW, Summe = Summe d. MW $\Rightarrow$ können kombinieren

Bsp: MW Angussumme (2x Würfel) Δ MW₁ + MW₂

Vorteile: Präzise, klar interpretierbar, hoher Informationsgehalt (nicht immer)

(Anteil α der extremsten Werte abgeschnitten, $r \leq$ große Zahl mit $r \leq n \cdot \alpha$)

Nachteile: Sehr empfindlich gegenüber Extremwerten u. Ausreißern

getrimmtes Mittel: $\bar{x}_\alpha = \frac{1}{n-2r} \sum_{i=r+1}^{n-r} x_{(i)}$

Das kann auch Vorteil sein, weil man Ausreißer ggf. direkt an komischem MW erkennt

gestutztes Mittel: wie oben, aber ersetze α -Werte durch oberste/untere Quantile

GEOMETRISCHES MITTEL Def: Der richtige MW für Merkmale, deren Ausprägungen als multiplikative Faktoren zu interpretieren sind

Voraussetzung: positive, mindestens intervallskalierte Merkmale

Bspw. Durchschnittl. Änderungsrate, Verzinsung, Rendite etc.

Berechnung: $\bar{x}_G = \sqrt[n]{\prod_{i=1}^n x_i} = \exp \left(\frac{1}{n} \sum_{i=1}^n \log(x_i) \right)$ rücktransformiertes arithmet. Mittel auf log-Skala

macht multiplikativ zu additiv $\Rightarrow$ auf log-Skala klassische MW-Berechnung

für $x_i \geq 0$: $\bar{x}_H \leq \bar{x}_G \leq \bar{x}$

Arithm. $\bar{x}_{log}$

Δ $\log$ (average) factor in product of x -Value before log-transf.

Anwendung: MW von Anteilen, Risikos

Harmonisches Mittel $\bar{x}_H = \frac{1}{\frac{1}{n} \sum_{i=1}^n 1/x_i} = \left(\frac{1}{n} \sum_{i=1}^n 1/x_i \right)^{-1}$

Streuungsmaße

Streuemaße von Bedeutungswerten um geeigneten Lageparameter

→ Was ist "normaler" Wert angesichts der Streuung?

Spannweite (Range) Definition: $SP = X_{\max} - X_{\min}$, also Größe des Daten-Intervalls

Anwendung primär zur Kontrolle der Datenqualität, Plausibilität, Eingabe-/Codierungfehler, Fehlmessungen, extreme Ausreißer etc.

Underschied gegenüber Ausreißern:

Quantilscheitel (QQR) ist spezielle Range, die sehr robust gegen Ausreißer ist!

Variationskoeffizient $V = \frac{S_X}{\bar{X}}$ mit $\bar{X} > 0$, macht nur Sinn bei „Relativer Schwankung um MW“ rein positiven Merkmalswerten.

Mittlere absolute Abweichung (MAD) *man absolute Deviation = exakte mittlere Abweichung vom MW*

Berechnung: $MAD_X = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{X}|$, wobei $MAD_X \leq \tilde{S}_X$ $\sum_{i=1}^n (x_i - \bar{X})$ immer = 0, siehe unten, aber für $|x_i - \bar{X}| > 0$

$Med(MD_X) = Median(|x_i - x_{med}|)$

Relative Abweichungen weniger empfindlich als Standardabweichung, vor allem in Median-Form. Verwendung bei „explorieren“ Datensätzen. Aber MAD_X hat nicht so schöne theoretische Eigenschaften wie S_X^2 und wird deswegen deutlich seltener angewendet!

(obwohl Interpretation von SD sehr schwierig ist!)

Standardabweichung und Varianz Voraussetzung: mindestens Intervallskala. Wichtig: sehr ausreißer-empfindlich

Stichproben-Varianz: $S_X^2 = \frac{1}{n-1} \sum (x_i - \bar{X})^2$ Statt $\frac{1}{n}$ Faktor $\frac{1}{n(n-1)}$ korrigiert Stichproben-Varianz (Unschätzung, Varianz um $\frac{n-1}{n}$)

⇒ vor allem bei kleinen samples wichtig und fällt weg bei Vollerhebung

Standardabweichung: $S_X = \sqrt{S_X^2}$

immer positive Zahl wie bei MAD_X, wobei $\sqrt{\quad}$ ziehen sich stellt, dass es kein Problem mit Einheit gibt

Schreibt $\tilde{S}_X$ bei Vollerhebung

Lineare Transformation (gleichsinnig MW-Transformierbarkeit): $y_i = a + b x_i \rightarrow \tilde{S}_Y^2 = b^2 \tilde{S}_X^2$ und $s_y = |b| s_x$

Verschiebungssatz $\left| \sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n (x_i - \bar{X})^2 + n(\bar{X} - c)^2, \forall c \in \mathbb{R} \right.$ $\sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n ((x_i - \bar{X}) + (\bar{X} - c))^2 = \sum_{i=1}^n ((x_i - \bar{X})^2 + 2(x_i - \bar{X})(\bar{X} - c) + (\bar{X} - c)^2)$

Setze $c = 0$: $\tilde{S}_X^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{X}^2$ $\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{X}^2$ kann das aus Reihe herausziehen, s.o.

= 0, da $\sum_{i=1}^n x_i - n\bar{X} = \sum_{i=1}^n x_i - \sum_{i=1}^n x_i = 0$

↪ $\tilde{S}_X^2 = \frac{\sum x_i^2}{n} - \bar{X}^2$ (gleichzeitiger MW) Verschiebungssatz Verzerrungsformel zur Berechnung der Varianz

MW (wird: Werte)

Aber Vorsicht: für präzise Zahlen, die Ergebnisse am Computer angezeigt (wegen Rundungsprozessen)

Streuungszerlegung Sehen die Daten in r-Schichten aufgeteilt, also $n = \sum_{j=1}^r n_j$ und $\bar{X} = \frac{1}{n} \sum_{j=1}^r n_j \bar{x}_j$

Dann gilt: $\tilde{S}_X^2 = \frac{1}{n} \sum_{j=1}^r n_j \tilde{S}_{x_j}^2 + \frac{1}{n} \sum_{j=1}^r n_j (\bar{x}_j - \bar{X})^2 = \frac{1}{n} \sum_{j=1}^r n_j (s_{x_j}^2 + (\bar{x}_j - \bar{X})^2)$

Gesamtstreuung = Streuung innerhalb Schichten + Streuung zwischen den Schichten

einzelner Schicht: Beispiel von X_j zu $MW_{Schicht j}$ + Abstand von $MW_{Schicht j}$ zu MW_{gesamt} $\cdot \frac{1}{n}$, also Gewichtung um Anteil an Stichprobe

⇒ Merkmale an der Streuung sind auch eine Art Streuungsmaß

Kennwerte - Verteilungseigenschaften



Modalität Anzahl stark konzentrierter ("dichter") Wertebereiche

stetige Dichte von ZV: Ein Modus vs. mehrere

stetige Gleichverteilung hat ∞ viele Modi, ganzes Intervall

Unimodal = Einspitzig

Multimodal = Mehrspitzig




→ solche Verteilung machen deskriptive Statistik mit üblichen Lagemaßen sehr schwierig

Symmetrie und Schiefe

Symmetrisch: Rechte u. linke Hälfte der Verteilung annähernd spiegelbildlich (siehe IV)

rechtsschief (linksteil): Verteilung links steiler, rechts flacher



linksschief (rechtsteil): Verteilung rechts steiler, links flacher

Formparameter verändern "shape" der Dichte, z.B. α, β bei Gamma-Vert.

Skalenparameter $\triangleq \text{Var}(X)$, IQR etc.

Lageregeln Faustregeln, bei gruppierten Daten auch für Histogramme gültig

Bei ZV mit Lageparametern $E(X)$, $\text{Med}(X)$, $\text{Mod}(X)$:

* Symmetrische + unimodale Verteilung $\Rightarrow \bar{X} \approx X_{\text{med}} \approx X_{\text{mod}}$

$E(X) = \text{Med}(X) = \text{Mod}(X)$ bei symmetr. unimod. ZV-Verteilung

$\Rightarrow$ Schiefe $\gamma(X) = 0$

unimodale
• Rechtsschiefe Verteilung $\Rightarrow \bar{X} > X_{\text{med}} > X_{\text{mod}}$

linksteil
X rechtsschief wenn Schiefe $\gamma(X) > 0$

unimodale
• Linksschiefe Verteilung $\Rightarrow \bar{X} < X_{\text{med}} < X_{\text{mod}}$

beliebige Lagemaße können Eindrucks verzerren
rechtsteil
X linksschief wenn Schiefe $\gamma(X) < 0$

Form der Verteilung bleibt bei linearen Transformationen gleich, ändert sich jedoch bei nichtlinearen Transformationen

Maßzahlen für Schiefe

Quantilkoeffizient $g_p = \frac{\tilde{x}_{1-p} - \tilde{x}_{\text{med}} - (\tilde{x}_{\text{med}} - \tilde{x}_p)}{\tilde{x}_{1-p} - \tilde{x}_p}$ ($0 < p < 0.5$)

Quantilkoeffizient $g_{0.25}$, oberes/unteres Quantil

→ unterschiedliches einsetzen

$g_p = 0$ für symmetrische Verteilungen

$g_p > 0$ für linkssteile, $g_p < 0$ für rechtssteile Verteilungen

Schiefe-Momentenkoeffizient $g_m = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3 \cdot \frac{1}{s_x^3}$ $g_m = 1 > 0$ gemäß wie oben

Wölbung und Extremwerte

Wichtige Verteilungseigenschaft: Wie häufig oder selten treten extreme Werte an Rändern der Verteilung auf?
(Ausreißer im Vergleich zur "Mitte")

Wölbung / Kurtosis misst Häufigkeit u. Distanz extremer Werte

$$K = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4 \cdot \frac{1}{s_x^4} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right)^4$$

Kurtosis sehr stark ($k^* \gg 0$) → viele Rechnungen werden unpraktisch

$k^* \approx$ normalgipflig

Meist betrachtet wird sog. **Exzess-Kurtosis** $k^* = k - 3$

$k^* > 0$ steilgipflig $\Rightarrow$ häufigere Extremwerte höher schmaler Gipfel im Vgl. zu Rändern

$k^* < 0$ flachgipflig $\Rightarrow$ seltenere Extremwerte tiefer breiterer Gipfel im Vgl. zu Rändern

Moment einer Zufallsvariablen

k-te Moment von ZV $X = E(X^k)$

EW: Erstes Moment e. Zufallsverteilung

k-te zentrierte Moment $= E((X - E(X))^k)$

Varianz: Zweites zentrierte Moment $\sim$ SD: zweites zentr.

Höhere Momente von ZV

Schiefe von Zufallsverteilung ist drittes (zentrales) Moment ihrer standardisierten Werte $E\left[\frac{(X - E(X))^3}{\sigma(X)}\right]$

Wölbung / Kurtosis ist viertes zentrales Moment der standardisierten Werte $E\left[\frac{(X - E(X))^4}{\sigma(X)^4}\right]$

Alle ungeraden Momente (außer 1-tes) messen Asymmetrie v. Zufallsverteilungen, Gewicht $\uparrow$ auf Asymmetrie in extremen Rändern
Alle geraden Momente $\triangleq$ "Varianzen" mit zunehmend mehr Gewicht auf extreme Ränder