

Kovarianz und Korrelation

$$\text{Cov}(-X, Y) = -\text{Cov}(X, Y)$$

Zufallsvariablen $X, Y: \Omega \rightarrow \mathbb{R}$

$$\text{Cov}(X, X) = \text{Var}(X) \quad \text{Varianz} \hat{=} \text{Kovarianz mit sich selbst}$$

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$$

$$\text{Verschiebungssatz: } \text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

$$\text{Cov} = 0 \text{ wenn } E(XY) = E(X)E(Y)$$

$$\text{Wenn } \text{Var}(X) \text{ und } \text{Var}(Y) > 0 \text{ ex. Korrelation } \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \cdot \sqrt{\text{Var}(Y)}}$$

$$\rho(X, Y) \in [-1, 1]$$

1. Linie: Maß für "gemeinsame Information" von X, Y

Kovarianz und Korrelation sind Maße für Stärke und Richtung (Cov kann < 0 sein) der linearen stochastischen Abh. von ZV.

Für Cauchy-Schwarz-Ungleichung folgt: $\text{Cov}^2(X, Y) \leq \text{Var}(X) \text{Var}(Y) \iff |\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}$

$$\rho(X, Y) \leq 1$$

Verschiebungssatz

Einschub zur Summe von Varianzen

$$\text{Var}(X+Y) = E((X+Y)^2) - (E(X+Y))^2$$

$$= E(X^2 + 2XY + Y^2) - (E(X) + E(Y))^2 = E(X^2) - (E(X))^2 + E(Y^2) - (E(Y))^2 + 2E(XY) - E(X)E(Y)$$

Nur für stochastisch unabh. ZV X, Y gilt also $\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y)$

$$\text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$$

$$X \perp Y \implies \text{Cov}(X, Y) = 0, \text{Cov}(X, Y) = 0 \text{ unkorreliert wenn } E(XY) = E(X)E(Y)$$

~~aus Unabhängigkeit folgt Unkorreliertheit, aber Umkehrschluss gilt im Allgemeinen nicht!~~ Logisch, denn Cov() erfasst nur lineare (un-)Abhängigkeit

Kovarianz-Eigenschaften

daraus wird auch Symmetrie $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ deutlich

Bilinearität (siehe Skalarprodukt - Interpretation von $\text{Cov}(\cdot, \cdot)$): $\text{Cov}(aX+b, cY+d) = ac \text{Cov}(X, Y)$

$$\text{Weil } \text{Var}(aX+b) = a^2 \text{Var}(X) \text{ folgt für Korrelation } \rho(aX+b, cY+d) = \frac{ac \text{Cov}(X, Y)}{\sqrt{a^2 \text{Var}(X)} \cdot \sqrt{c^2 \text{Var}(Y)}} = \rho(X, Y)$$

$\implies$ Korrelation invariant bzgl. linearer Transformationen

Stetige ZV: Zweidimensionales Integral $\text{Cov}(X, Y) = \iint (x - E(X))(y - E(Y)) f_{X,Y}(x, y) dx dy$

Beweis: Wenn $X \perp Y$ (beide diskrete ZV) $\implies E(XY) = E(X)E(Y)$

$$\text{Diskrete ZV: Doppelsumme } \text{Cov}(X, Y) = \sum_i \sum_j (x_i - E(X))(y_j - E(Y)) f_{X,Y}(x_i, y_j)$$

Indizes i-für $X \in \mathbb{R}$, j-für $Y \in \mathbb{R}$

$$f(x_i, y_j)$$

$$E(XY) = \sum_i \sum_j x_i y_j f_{X,Y}(x_i, y_j) = \sum_i \sum_j x_i y_j f_X(x_i) f_Y(y_j) = \sum_i x_i f_X(x_i) \sum_j y_j f_Y(y_j) = E(X)E(Y)$$

Für Stetige ZV analog mit $\int \dots dx$ statt $\sum$

Multivariat

Kovarianzmatrix

n-dimensionale ZV $X: \Omega \rightarrow \mathbb{R}^n$, $X = (X_1, \dots, X_n)$ Zufallsvektor

$$= E[(X_i - E(X_i))(X_j - E(X_j))]$$

Symmetrisch zur Hauptdiagonale: $\text{Cov}(X)_i,j = \text{Cov}(X)_j,i$

$$\text{Cov}(X) = E[(X - E(X))(X - E(X))^T] \in \mathbb{R}^{n \times n}$$

Kov.matrix ist symmetrisch

Diagonalelemente: $\text{Cov}(X)_i,i = \text{Var}(X_i)$

$$\text{Elemente } \text{Cov}(X)_i,j \text{ berechnen mithilfe von Summe von Varianzen } \text{Cov}(X_i, X_i) = \frac{1}{2} \cdot [\text{Var}(X_i + X_i) - (\text{Var}(X_i) + \text{Var}(X_i))] = 0 \text{ falls } X_i \perp X_i$$

nützlich, falls $\text{Var}(X_i + X_i)$ unabhängig bestimmbar z.B. über bekannte Verteilung von $X_i + X_i$

Sei Σ^{Cov} Kovarianzmatrix und $\text{diag}(\Sigma^{\text{Cov}})$ die Matrix der reinen Diagonalelemente von Σ^{Cov}

$$\text{Korrelationsmatrix } R = \text{Corr}(X) = \text{diag}(\Sigma)^{-1/2} \cdot \Sigma \cdot \text{diag}(\Sigma)^{-1/2}$$

Korrelationsmatrix ist symmetrisch

Hauptdiagonale: $\rho(X_i, X_i) = 1$

$$\text{Symmetrische Eiem. } \rho(X_i, X_i) = \sqrt{\frac{\text{Cov}(X_i, X_i)}{\text{Var}(X_i) \text{Var}(X_i)}}$$

Eigenschaften von Kovarianzmatrix $X: \Omega \rightarrow \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$

$$i) E(AX+b) = A \cdot E(X) + b \text{ linearität mehrdimensionaler EV}$$

EV linear

$$ii) \text{Cov}(AX+b) = A \text{Cov}(X) A^T$$

$$\text{Cov}(AX+b) = E[(AX+b - E(AX+b))(AX+b - E(AX+b))^T] = E[(AX+b - E(AX+b))(AX+b - E(AX+b))^T] = E[A(X - E(X))(X - E(X))^T A^T] = A E[(X - E(X))(X - E(X))^T] A^T = A \text{Cov}(X) A^T$$

$$\stackrel{\text{EV}}{=} \text{Cov}(AY) = 0$$

iii) Kov.matrix positiv semidefinit, also $y^T \text{Cov}(X) y \geq 0 \forall y \in \mathbb{R}^n$ für $n=1$ $\text{Var}(X) \geq 0$ $y^T \text{Cov}(X) y = \dots = y^T X y$ in $E[\dots]$ interpretieren $\dots = E[(y^T X - y^T E(X))^2]$

Standardisierung

Es gibt inverse Matrix $B \in \mathbb{R}^{n \times n}$ sodass für $\tilde{X} = B^{-1}(X - \mu) : E(\tilde{X}) = 0_n$, $\text{Cov}(\tilde{X}) = I_n$

$E(X)$ und $\text{Pos. defn. } \Sigma^{\text{Cov}}$ muss ex.

Zusammenhangsmaße für metrische Merkmale

Empirische Kovarianz

Kennzahl für Stärke u. Richtung von Zusammenhang zweier Merkmale X, Y Daten $(x_i, y_i), i \in \{1, \dots, n\}$

$$S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$S_{XX} = S^2 \text{ Varianz von } X, \quad \bar{S}_X^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \|x - \bar{x}\|^2 \Rightarrow \bar{S}_X = \frac{1}{\sqrt{n}} \|x\|$$

Korrektur bei sample

$$\bar{S}_{XY} = \frac{1}{n} \langle x^*, y^* \rangle$$

$(\bar{x}, \bar{y})$

Geometrische Interpretation: Kovarianz entspricht gdb. Summe der 2D-Gewichte der Abweichungen vom Schwerpunkt des Streudiagramms

positive x_i : Pos. vom Mittelwert $\bar{x}$ & positive y_i : Abweichung von $MW_Y \hat{=}$ positiver Beitrag zu Kovarianz / Die aufsummierte Fläche über
negative x_i : Abweichung & positive y_i : Pos., $\hat{=}$ positiver Beitrag / alle $i=1, \dots, n$ (positiv/negativ)
positive x_i : Abweichung & negative y_i : Abweichung oder umgekehrt $\hat{=}$ negativer Beitrag / ergibt Kovarianz
keinerlei Abweichung in x - oder y -Richtung, also x_i oder y_i exakt $MW \hat{=}$ Beitrag Null

Zahlen S_{XY} vergleichen von $\bar{S}_{XY}$

Pearson-Korrelation - Misst nur nach Stärke u. Richtung von linearem Zusammenhang (Kovarianz misst auch Größe der Streuungen)

- dimensionsloses Maß (Kovarianz hat Problem mit Einheiten)

$$r_{XY} = \frac{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \cdot \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2} = \frac{S_{XY}}{S_X S_Y}$$

ausgeglichen

4/n wieder rein

Schöne Darstellung mit lineare Algebra: $\bar{r}_{XY} = \frac{\langle x^*, y^* \rangle}{\|x^*\| \|y^*\|} = \cos \angle(x^*, y^*)$

Wieder Information haben x und y (jeweils zentriert) gemeinsam?

in linearer Spanne

stehe linear, gemessene Skalierungslänge entspricht $\cos$ (Winkel zw. Vektoren)

Pearson-Korrelation ändert bei linearer Transformation höchstens das Vorzeichen X, Y mit unterschiedl. Vorseichen skalieren) und ist symmetrisch

bzw. einseitig negativ

$r_{XY} \in [-1, 1]$

positive (negative) Korrelation bedeutet: Je größer X , desto größer (kleiner) im Durchschnitt Y und umgekehrt

$r_{XY} = 1 \Rightarrow y_i = a + b \cdot x_i$

Kor = 1 ist perfekter linearer Zusammenhang (oder identische Werte bzw. unterschiedl. Skala derselben Messung)

$r_{XY} = 0$ unkorreliert i. S.v. idemeitel lineare Beziehung, gilt nur wenn $S_{XY} = 0$

Vorsicht: kein linearer Zusammenhang bedeutet nicht, dass es überhaupt keine Abhängigkeit gibt!

* Erstmal alles Ecken-trüßige. Steigung der Gerade egal, es geht ja um Streuung um diese Gerade. Beinh=1 perfekte Gerade ohne Streuung.

Probleme: Kovarianz und Korrelation empfindlich geg. Ausreißern

- Erfasst nichtlineare Zusammenhänge schlecht bis gar nicht. Monotoner Zusammenhang $\Rightarrow$ Monotonie Transform.
- brauchen mindestens Intervallskala, Ordinalskala nicht erweitert

Alternative Zusammenhangsmaße (nicht parametrisch)

Spearman Rang-Korrelation

X, Y können auch nur ordinalskaliert sein, oder eines metrisch und eines ordinal

Spearman-Korrelation ändert bei monotoner Transformation höchstens Vorzeichen (ausreißern mon. steigend/fallend MW) es zählt Rang-Platz und Idee: Berechne Pearson-Korrelation für Ränge statt Werte der Merkmale $\Rightarrow$ Distanz zu Datenmasse irrelevant, und Beziehung zwischen

Urliste der Größe nach sortieren $\Rightarrow$ Ränge für jedes x_i, y_i

Bei Bindungen (ties) also identischen Werten wird Durchschnittswert vergeben, etwa $\frac{3+4}{2} = 3.5$

$$r_{XY}^{SP} = \frac{Z(R(x_i) - \bar{R}_X)(R(y_i) - \bar{R}_Y)}{\sqrt{Z(R(x_i) - \bar{R}_X)^2} \sqrt{Z(R(y_i) - \bar{R}_Y)^2}} = \frac{S_{RX RY}}{S_{RX} S_{RY}}$$

$$r_{XY}^{SP} \in [-1, 1]$$

transformiert monoton $r_{XY}^{SP} = 1 - \frac{6 \sum d_i^2}{(n-1)n(n+1)}$

Unterschied vs. Pearson: - Erfasst alle monotonen Zusammenhänge, zu linearem Rang-Korrelation
- Robuster, unempfindlich ggü. Ausreißern (siehe auch Robustheit von Quartilen und Median ebenfalls Rang-basierte Kennzahlen)

z.B. ordinale Daten mit wenig Ausreißern (kleiner Subtyp)

Kendalls Tau

Paarvergleichsmaß konstante Paare (x_i, x_j) und (y_i, y_j) : $x_i < x_j$ oder $x_i > x_j, y_i > y_j$

diskontante Paare: $x_i < x_j, y_j < y_i \Rightarrow$ Rangfolge der x -Werte umgekehrt zu y -Werte
Wenn X oder Y nur sehr wenige Ausreißer hat, bis hin zu unigen $y = z$ viele Paare mit Bindungen in Y
insgesamt $n(n-1)/2$ negative Paare $r_{XY} = 1 - \frac{6 \sum d_i^2}{(n-1)n(n+1)}$ in der Regel $\hookrightarrow$ Somers J $D_{XY} = (M_C - M_D) / \text{Anzahl Paare mit ungleichen } Y$